



Universidad Internacional de la Rioja

Escuela Superior de Ingeniería y
Tecnología

Máster universitario en Inteligencia artificial

Sistema de recomendación de carteras de inversión

Trabajo fin de estudio presentado por:	Edelmín Rodríguez Castro
Tipo de trabajo:	Desarrollo de software
Director/a:	Omar Velázquez López
Fecha:	16 de septiembre de 2026

Resumen

El diseño de carteras de inversión exige seleccionar y ponderar activos equilibrando rentabilidad y riesgo, tarea que combina modelos matemáticos rigurosos con el tratamiento de grandes volúmenes de datos históricos. Este trabajo diseña, construye y valida una herramienta software de apoyo a la construcción de carteras que integra la predicción de retornos mediante redes neuronales recurrentes (RNN, GRU y LSTM), seleccionadas por optimización de hiperparámetros, con la optimización de Markowitz para asignar los pesos, y ofrece al usuario varias estrategias de recomendación. El universo lo forman empresas de gran capitalización de once sectores, con dieciséis años de datos. La herramienta se valida mediante backtesting out-of-sample frente al índice S&P 500, con métricas de rentabilidad ajustada al riesgo (ratio de Sharpe, ratio de Sortino y máximo *drawdown*). Los resultados muestran una utilidad dependiente del horizonte y del conjunto de información, y se complementan con un análisis de explicabilidad de las decisiones.

Palabras clave: recomendación de carteras, redes neuronales recurrentes, optimización de Markowitz, backtesting, ratio de Sharpe

Abstract

Portfolio construction requires selecting and weighting assets while balancing return and risk, a task that combines rigorous mathematical models with the processing of large volumes of historical data. This work designs, builds and validates a software tool to support portfolio construction that integrates return prediction based on recurrent neural networks (RNN, GRU and LSTM), selected through hyperparameter optimization, with Markowitz optimization to assign the weights, and offers the user several recommendation strategies. The investment universe comprises large-cap companies from eleven sectors, spanning sixteen years of data. The tool is validated through out-of-sample backtesting against the S&P 500 index, using risk-adjusted performance metrics (Sharpe ratio, Sortino ratio and maximum drawdown). The results show a usefulness that depends on the horizon and the information set, and are complemented by an explainability analysis of the decisions.

Keywords: portfolio recommendation, recurrent neural networks, Markowitz optimization, back-testing, Sharpe ratio

Índice de contenidos

1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del trabajo	4
1.3. Estructura del trabajo	6
2. Contexto y estado del arte	7
2.1. Contexto del problema	7
2.2. Estado del arte	7
2.3. Conclusiones sobre el estado del arte	15
3. Objetivos concretos y metodología del trabajo	16
3.1. Objetivo general	16
3.2. Objetivos específicos	16
3.3. Metodología del trabajo	17
4. Identificación de requisitos	18
4.1. Requisitos funcionales	18
4.2. Requisitos no funcionales	20
4.3. Relación entre requisitos y objetivos	21
5. Descripción de la herramienta de software desarrollada	22
5.1. Diseño conceptual	22
5.2. Módulo de adquisición y preparación de datos	26
5.2.1. Muestreo estratificado	26
5.2.2. Normalización de divisas	27
5.2.3. Limpieza y preprocesamiento	27
5.3. Módulo de consolidación e ingeniería de características	30
5.3.1. Construcción del dataset de empresa	30
5.3.2. Métricas derivadas y notación temporal	31

5.3.3.	Generación de los conjuntos de features	33
5.3.4.	Escalado robusto	36
5.3.5.	Partición temporal	37
5.3.6.	Ventanas temporales	38
5.4.	Módulo de predicción de precios	40
5.4.1.	Arquitectura del modelo predictivo	40
5.4.2.	Entrenamiento	41
5.4.3.	Optimización de hiperparámetros	42
5.4.4.	Parada temprana y selección del mejor modelo	43
5.5.	Módulo de construcción de carteras	44
5.5.1.	Selección de activos	44
5.5.2.	Notación común	44
5.5.3.	Estrategia de máximo retorno	46
5.5.4.	Estrategia de mínima varianza	46
5.5.5.	Estrategia de media-varianza	47
5.5.6.	Estrategia de retorno objetivo	47
5.5.7.	Estimación de la matriz de covarianza	48
5.5.8.	Rebalanceo periódico	48
5.6.	Módulo de evaluación y backtesting	48
5.6.1.	Los dos backtests: validación y test	48
5.6.2.	Proceso de backtesting	49
5.6.3.	Métricas de rendimiento de carteras	50
5.7.	Módulo de explicabilidad de las decisiones	50
5.8.	Entorno de ejecución	52
5.9.	Ejecución de la herramienta	53
6.	Evaluación	54
6.1.	Configuración experimental	54

6.1.1.	Métricas de evaluación del modelo predictivo	54
6.2.	Análisis de arquitecturas	56
6.2.1.	Curvas de aprendizaje y parada temprana	59
6.3.	Discusión de resultados	60
6.4.	Evaluación de carteras Markowitz	62
6.4.1.	Configuración del backtesting de carteras	63
6.4.2.	Resultados del backtesting	66
6.4.3.	Discusión de los resultados	77
6.5.	Explicabilidad de las decisiones	79
6.5.1.	Trazabilidad de la cadena de decisión	79
6.5.2.	Descomposición de la optimización de Markowitz	80
6.5.3.	Atribución de variables de la red recurrente	80
6.6.	Limitaciones identificadas	83
6.7.	Conclusiones de la evaluación	84
7.	Conclusiones y trabajo futuro	86
7.1.	Conclusiones	86
7.2.	Cumplimiento de los requisitos	88
7.3.	Líneas de trabajo futuro	89
8.	Anexo A. Código fuente y datos analizados	90
9.	Anexo B. Curvas de aprendizaje y parada temprana	91
9.1.	Conjunto <i>market</i>	91
9.2.	Conjunto <i>enriched</i>	94

Índice de figuras

5.1. Diagrama del flujo general del sistema.	25
5.2. Construcción de las ventanas temporales deslizantes, para el horizonte de 1 día.	39
6.1. Curvas de aprendizaje por semilla (conjunto market, horizonte 1 semana).	60
6.2. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 semana).	61
6.3. Diferencial de ratio de Sharpe respecto al S&P 500 por configuración y horizonte sobre el conjunto <i>market</i>	66
6.4. Distribución del ratio de Sharpe por horizonte (todas las configuraciones) sobre el conjunto market	67
6.5. Dispersión retorno-riesgo de todas las configuraciones, conjunto <i>market</i> , con el S&P 500 como referencia.	68
6.6. Distribución del ratio de Sortino por horizonte (todas las configuraciones), conjunto market, con las referencias de mercado superpuestas.	69
6.7. Dispersión retorno-drawdown de todas las configuraciones, conjunto market.	70
6.8. Diferencial de ratio de Sharpe respecto al S&P 500 por configuración y horizonte sobre el conjunto enriched.	72
6.9. Distribución del ratio de Sharpe por horizonte (todas las configuraciones) para el conjunto enriched.	72
6.10. Distribución del ratio de Sortino por horizonte (todas las configuraciones) para el conjunto <i>enriched</i>	73
6.11. Dispersión retorno-riesgo de todas las configuraciones, conjunto enriched.	74
6.12. Dispersión retorno-drawdown de todas las configuraciones para el conjunto enriched.	75
6.13. Curvas de equity para la configuración top-10, para el dataset market.	76
6.14. Curvas de equity para la configuración top-10 para el dataset enriched.	77
6.15. Trazabilidad para un rebalanceo (conjunto <i>market</i> , horizonte semanal, top-10 <i>long-only</i>).	80
6.16. Descomposición de la asignación de Markowitz por activo (conjunto market, horizonte semanal, top-10 <i>long-only</i>).	81
6.17. Importancia global de variables mediante Integrated Gradients (conjunto market, horizonte semanal).	82

6.18. Importancia global de variables mediante Integrated Gradients (conjunto enriched, horizonte diario).	82
9.1. Curvas de aprendizaje por semilla (conjunto market, horizonte 1 día).	91
9.2. Curvas de aprendizaje por semilla (conjunto market, horizonte 2 semanas). . .	92
9.3. Curvas de aprendizaje por semilla (conjunto market, horizonte 1 mes).	92
9.4. Curvas de aprendizaje por semilla (conjunto market, horizonte 2 meses).	93
9.5. Curvas de aprendizaje por semilla (conjunto market, horizonte 3 meses).	93
9.6. Curvas de aprendizaje por semilla (conjunto market, horizonte 6 meses).	94
9.7. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 día).	94
9.8. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 2 semanas). .	95
9.9. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 mes).	95
9.10. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 2 meses). . . .	96
9.11. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 3 meses). . . .	96
9.12. Curvas de aprendizaje por semilla (conjunto enriched, horizonte 6 meses). . . .	97

Índice de cuadros

2.1. Selección de trabajos representativos del estado del arte.	15
4.1. Correspondencia entre objetivos específicos y requisitos funcionales.	21
5.1. Campos extraídos de los estados financieros.	31
5.2. Horizontes de predicción soportados por el sistema, con su duración en sesiones bursátiles (h).	33
5.3. Conjunto de características del conjunto <i>market</i>	33
5.4. Features adicionales del conjunto <i>enriched</i> sobre las de <i>market</i> (total 26 variables).	35
5.5. Partición temporal de los datos.	37
5.6. Entorno de ejecución empleado en el desarrollo y la experimentación.	52
6.1. Configuración ganadora por horizonte tras la optimización de hiperparámetros.	57
6.2. Métricas del <i>ensemble</i> de 5 semillas con la configuración ganadora de cada horizonte sobre el conjunto de test.	58
6.3. Parámetros de configuración del backtesting de carteras.	63
6.4. Número de rebalanceos disponibles por horizonte sobre el conjunto de test (finales de 2021 a finales de 2024).	65
6.5. Configuraciones de media-varianza del conjunto <i>market</i> en el peor cuadrante frente al S&P 500.	71
6.6. Configuraciones con ratio de Sortino superior a 10 (conjunto <i>enriched</i> , periodo de <i>test</i>). Se muestra su ratio de Sharpe como contraste.	73
7.1. Evaluación del cumplimiento de requisitos funcionales.	88
7.2. Evaluación del cumplimiento de requisitos no funcionales.	88

1. Introducción

El diseño de carteras de inversión es un problema central en el ámbito financiero, donde no solo resulta esencial determinar qué activos deben formar parte de la cartera, sino también establecer con qué peso deben participar en ella, siempre bajo un equilibrio entre rentabilidad y riesgo. Este objetivo resulta fundamental para cualquier inversor, cuya prioridad es maximizar el beneficio asumiendo niveles de riesgo previamente controlados y aceptables. Para abordar de forma sistemática este equilibrio entre rentabilidad y riesgo, se han desarrollado a lo largo del tiempo distintos marcos cuantitativos, entre los que destaca por su influencia la formulación clásica del problema.

La aproximación clásica a este problema se realiza mediante la teoría de carteras de Markowitz, que optimiza la asignación de pesos bajo la premisa de maximizar la rentabilidad esperada para un nivel de riesgo determinado, generalmente medido mediante la varianza de los retornos. Sin embargo, este modelo presenta ciertas limitaciones prácticas. Por un lado, es altamente sensible a errores de estimación en los parámetros de entrada, lo que puede generar resultados inestables. Por otro lado, la suposición de normalidad en los retornos financieros y la utilización de la varianza como única medida de riesgo pueden no ajustarse adecuadamente a la realidad de los mercados financieros, especialmente en entornos de alta volatilidad o cuando se producen fenómenos de cola pesada¹.

A estas limitaciones se suma el hecho de que la selección previa de activos suele estar condicionada por la experiencia subjetiva de analistas financieros, lo que dificulta la incorporación de grandes volúmenes de datos y puede limitar la identificación de patrones complejos. En este contexto, el uso de técnicas de inteligencia artificial se presenta como una alternativa prometedora. Concretamente, las redes neuronales recurrentes tipo GRU permiten capturar patrones no lineales y dinámicos en las series temporales de precios, facilitando tanto la predicción de valores futuros como la automatización parcial del proceso de selección de activos. Estas metodologías tienen el potencial de reducir la dependencia del criterio humano, mejorar la capacidad predictiva y optimizar la eficiencia riesgo-retorno de las carteras.

¹ Se describe así a las distribuciones de probabilidad que presentan una gran asimetría o curtosis, en relación a una distribución normal o exponencial. En el ámbito de las finanzas, este término se atribuye al hecho de que las fluctuaciones de precio no se ajustan del todo a una distribución normal, debido a que pueden tener lugar grandes subidas o caídas agresivas de los precios del activo financiero. Por ejemplo, las fluctuaciones ocurridas tras la burbuja de las puntocom o la pandemia del covid-19.

La literatura académica reciente respalda este enfoque, mostrando cómo la integración de modelos basados en aprendizaje profundo con técnicas clásicas de optimización puede superar en diversas métricas, como la rentabilidad acumulada o el ratio de Sharpe, a los métodos tradicionales. Por ello, resulta de especial interés desarrollar una herramienta software que materialice esta integración (predicción de precios mediante redes neuronales y construcción de carteras mediante optimización de Markowitz) y que permita evaluar el valor añadido que estas técnicas pueden ofrecer en la toma de decisiones financieras.

No obstante, la incorporación de modelos de aprendizaje profundo en un dominio de alto impacto como el financiero introduce un requisito adicional que no puede obviarse: la explicabilidad. A diferencia de los métodos tradicionales, cuyo funcionamiento resulta transparente y fácilmente interpretable, las redes neuronales operan frecuentemente como cajas negras, lo que dificulta comprender las razones que sustentan sus predicciones. En un contexto de recomendación de carteras, donde las decisiones pueden acarrear consecuencias económicas relevantes para el inversor, no basta con ofrecer estimaciones precisas de rentabilidad, riesgo y pesos; resulta igualmente necesario poder justificar de forma comprensible por qué se seleccionan determinados activos y con qué proporción participan en la cartera. La capacidad de aportar trazabilidad e interpretabilidad al proceso de recomendación favorece la confianza del usuario, facilita la validación de los resultados y constituye, por tanto, un aspecto que este trabajo considera de especial relevancia.

1.1. Motivación

El ámbito financiero constituye un campo de aplicación especialmente relevante para las matemáticas, ya que numerosos problemas asociados a la valoración de activos, la medición del riesgo y la toma de decisiones bajo incertidumbre requieren una formulación cuantitativa rigurosa. En este contexto, los modelos matemáticos no se limitan a una dimensión teórica, sino que permiten abordar problemas con una aplicación directa en la gestión de inversiones y en el análisis del comportamiento de los mercados financieros. Es precisamente esa capacidad de trasladar la formulación matemática a decisiones concretas la que despertó un interés personal por esta disciplina.

Dicho interés surge a partir del trabajo desarrollado durante el Grado en Matemáticas, especial-

mente a través del Trabajo de Fin de Grado, donde se tuvo un primer contacto con las matemáticas financieras. Esta experiencia permitió apreciar la relevancia de los métodos cuantitativos en el estudio de los mercados y motivó la continuación de esta línea en el presente Trabajo de Fin de Máster, incorporando ahora técnicas de inteligencia artificial aplicadas a la gestión de carteras de inversión.

La construcción de carteras es un problema complejo, en el que no solo resulta necesario seleccionar adecuadamente los activos que formarán parte de la inversión, sino también determinar los pesos asignados a cada uno de ellos. Esta decisión depende, en gran medida, de la estimación de la rentabilidad y del riesgo esperado, lo que introduce una dificultad significativa debido al carácter incierto, dinámico y no lineal de los mercados financieros. En particular, la predicción de precios futuros constituye una de las tareas más complejas dentro de este proceso, ya que pequeñas desviaciones en las estimaciones pueden tener un impacto considerable sobre la composición final de la cartera y sobre su rendimiento posterior.

A esta dificultad se añade la necesidad de que el proceso de recomendación resulte interpretable para el inversor. Cuando una decisión de inversión se apoya en modelos automáticos, conviene no solo estimar la rentabilidad y el riesgo, sino también poder explicar de forma comprensible por qué se recomiendan determinados activos y con qué peso participan en la cartera. Esta trazabilidad refuerza la confianza en la recomendación y facilita su evaluación por parte del usuario, lo que motiva prestar atención a la interpretabilidad a lo largo del trabajo.

En esta línea, las técnicas de inteligencia artificial se presentan como una alternativa de interés para complementar los enfoques clásicos de la matemática financiera. Concretamente, las redes neuronales recurrentes permiten modelar dependencias temporales en series históricas de precios y capturar patrones que pueden no ser fácilmente identificables mediante métodos tradicionales. Entre estas arquitecturas, los modelos de redes neuronales recurrentes resultan especialmente adecuados para el tratamiento de series temporales financieras, al ofrecer una estructura capaz de incorporar información pasada de forma eficiente y generar predicciones que pueden ser utilizadas posteriormente en el proceso de construcción de carteras.

La combinación entre modelos financieros clásicos y técnicas modernas de aprendizaje automático permite plantear un marco de análisis en el que las predicciones obtenidas mediante redes neuronales pueden integrarse en metodologías de optimización y selección de activos.

De este modo, resulta posible estudiar la incorporación de modelos predictivos para mejorar la eficiencia riesgo-retorno de las carteras, así como comparar su comportamiento frente a enfoques tradicionales y benchmarks de referencia.

Por tanto, el presente Trabajo de Fin de Máster se justifica tanto desde una perspectiva académica como aplicada. Por un lado, permite profundizar en el estudio de la matemática financiera y de los modelos de gestión de carteras y, por otro, ofrece la posibilidad de evaluar el valor añadido de las técnicas de inteligencia artificial en un problema realista de toma de decisiones financieras. Esta aproximación resulta de especial interés para analizar hasta qué punto puede existir una sinergia positiva entre los modelos tradicionales de optimización de carteras y las metodologías emergentes basadas en aprendizaje profundo.

1.2. Planteamiento del trabajo

En consonancia con lo presentado hasta ahora, el problema central que se abordará es el de configurar una cartera de inversión. Así, será necesario poder determinar qué activos deben participar en la cartera y, además, determinar en qué porcentaje debe participar cada uno en ella atendiendo al perfil de riesgo-beneficio que desee adoptar el inversor. Para abordarlo, este trabajo se orienta a la construcción de una herramienta software que automatice el proceso completo de recomendación, desde la preparación de los datos hasta la generación y evaluación de las carteras.

El modelo de Markowitz ofrece un método cuantitativo para resolver este problema a partir de dos ingredientes esenciales. El primero es la rentabilidad esperada de cada activo, que refleja cuánto se espera que gane cada uno y orienta la asignación hacia los más prometedores. El segundo es la estructura de riesgo del conjunto de activos, descrita por su matriz de covarianza, que recoge no solo la variabilidad individual de cada activo sino, sobre todo, el grado en que sus movimientos están relacionados entre sí. Este segundo ingrediente es el que induce la diversificación: al penalizar las combinaciones de activos que tienden a subir y bajar a la vez, la optimización favorece de forma natural carteras en las que las oscilaciones de unos activos compensan las de otros, reduciendo el riesgo global sin necesidad de imponer restricciones explícitas de correlación.

Sobre estos dos ingredientes, el modelo admite distintas formulaciones que comparten la mis-

ma lógica pero expresan de manera diferente el equilibrio entre rentabilidad y riesgo. Una posibilidad es fijar un nivel de riesgo máximo y maximizar la rentabilidad esperada dentro de ese límite; otra es buscar directamente la cartera de mínima varianza; otra, combinar ambos objetivos en una única función que pondera rentabilidad y riesgo según la aversión del inversor; y otra más, fijar una rentabilidad objetivo y minimizar el riesgo necesario para alcanzarla. Todas ellas derivan del mismo marco media-varianza y se abordan en este trabajo como alternativas de recomendación entre las que el usuario puede decidir. La cartera puede además restringirse, por ejemplo, a posiciones puramente compradoras o permitir posiciones a la baja, y limitar la concentración máxima por activo. En la formulación que fija el riesgo, se adopta por defecto un umbral del 20%, un valor empleado habitualmente en la literatura como cota de volatilidad admisible para la cartera (Cui et al., 2025; Mugel et al., 2021).

Una vez fijados los parámetros del modelo —el nivel de riesgo admisible o la rentabilidad objetivo— y estimada la matriz de covarianza a partir de datos históricos, la optimización de la cartera queda determinada por las rentabilidades esperadas. Por tanto, el principal elemento que debe estimarse es el rendimiento futuro de los activos. En este punto interviene la inteligencia artificial, mediante modelos predictivos que estiman dicha evolución y proporcionan las entradas necesarias para optimizar la cartera.

Para conseguirlo, se dispondrá de datos sobre los precios históricos de las acciones y de los estados financieros de las empresas cotizadas.

Entre las empresas cotizadas es habitual distinguir distintos grupos atendiendo a su capitalización de mercado. Esta distinción resulta relevante porque las empresas de menor capitalización tienden a presentar una mayor volatilidad e inestabilidad en el precio de sus acciones que aquellas de mayor tamaño, si bien también se asocian en ocasiones a mayores retornos (Switzer, 2010).

No existe un criterio único para delimitar estos grupos. Por lo general, se considera *large cap* a las empresas cuya capitalización supera los 10 $B\$$ ², *small cap* a las que se sitúan por debajo de 2 $B\$$ y *mid cap* a las comprendidas entre ambos umbrales (Naidoo et al., 2025). Algunos autores distinguen grupos adicionales, identificando como *mega cap* a las empresas que superan los 200 $B\$$ (Valentine et al., 2026). En el ámbito regulatorio también se emplea este criterio:

² B : *billions*, según la medida americana. Es decir, un *billion* equivale a mil millones.

el Comité de Supervisión Bancaria de Basilea, dentro del método estándar para el riesgo de mercado, establece un marco que clasifica las exposiciones de renta variable atendiendo, entre otros criterios, a la capitalización bursátil, y define como emisores de gran capitalización (*large market cap*) a aquellos cuya capitalización es igual o superior a 2 B\$ ([Basel Committee on Banking Supervision, 2026](#)).

Por ello, en lo que sigue se distinguirán con especial interés los grupos de small cap y large cap, y se planteará el diseño de la cartera de inversión sobre las empresas consideradas *large cap*. En concreto, el universo de estudio se acota a las empresas con una capitalización de mercado igual o superior a 2 B\$, que constituye la cota inferior efectiva del conjunto de datos empleado en este trabajo.

1.3. Estructura del trabajo

La estructura del presente trabajo se organiza en siete capítulos. Tras la introducción vista en este primer capítulo, el Capítulo 2 presenta el contexto general del estudio, introduciendo los conceptos fundamentales necesarios para comprender el desarrollo posterior. Así mismo, se hace una revisión del estado del arte relativo a la aplicación de técnicas de inteligencia artificial en la predicción de precios financieros y en el diseño de carteras de inversión.

El Capítulo 3 expone los objetivos generales y específicos del trabajo, así como la metodología seguida para alcanzarlos. Posteriormente, el Capítulo 4 identifica los requisitos funcionales y técnicos que guían el desarrollo de la herramienta, junto con las hipótesis de partida y las principales asunciones realizadas para delimitar el alcance del sistema.

Seguidamente, el Capítulo 5 describe la herramienta software desarrollada, detallando su arquitectura, sus módulos principales, el flujo de funcionamiento, las decisiones de diseño y las estrategias implementadas. Posteriormente, el Capítulo 6 aborda la validación de la herramienta, comprobando la corrección de su funcionamiento y analizando el rendimiento de las carteras generadas mediante las métricas y *benchmarks* definidos, con especial atención a la validez de los resultados obtenidos. Finalmente, el Capítulo 7 recoge las conclusiones del trabajo y plantea posibles líneas de investigación y mejora futura.

2. Contexto y estado del arte

Comprender el trabajo desarrollado exige recopilar previamente algunos conceptos básicos que resultan clave para entender el contexto del problema y los datos sobre los que se apoya el desarrollo.

2.1. Contexto del problema

En primer lugar, se compondrá la base sobre la que se construirán los desarrollos realizados en el presente trabajo. Para ello, definiremos formalmente los elementos que intervienen en las relaciones financieras y se abordará el problema de crear la cartera de inversión, como objeto de estudio.

Un activo financiero es un valor que acredita la titularidad de determinados derechos económicos ([Comisión Nacional del Mercado de Valores, s.f.-a](#)). Aquí debemos entender como "derecho" la capacidad legal de la persona que posee el activo de reclamar para sí en el momento que desee el activo real (por ejemplo un bien, servicio, dinero, etc.) y el efectivo que genere, de forma que la contraparte está en la obligación de entregarlo. Existen diferentes tipos de activos financieros, como los bonos, las acciones, los futuros, las opciones e incluso obras de arte, entre otros.

Por otro lado, los mercados financieros se definen como el espacio virtual o físico donde pueden intercambiarse distintos tipos de activos financieros entre los distintos agentes económicos y donde se define el precio de dichos activos ([Castro Sesme, 2017](#)). Aquí, los agentes económicos son aquellos que participan de la compra y venta de activos financieros.

A partir de un conjunto de activos financieros, conformamos lo que se denomina una cartera de inversión, cartera de valores o portafolio. Ésta se define como el conjunto de activos financieros que posee una persona física o jurídica ([Comisión Nacional del Mercado de Valores, s.f.-b](#)).

2.2. Estado del arte

Los estudios bibliométricos recientes no solo evidencian un crecimiento sostenido de la producción científica en la intersección entre la inteligencia artificial y los mercados financieros,

sino también una progresiva diversificación de sus ámbitos de aplicación. La literatura ha evolucionado desde un enfoque centrado principalmente en la predicción de precios hacia áreas como el trading algorítmico, la valoración de activos, la optimización de carteras basada en datos, el aprendizaje por refuerzo y el desarrollo de sistemas de decisión adaptativos. [Mohamad et al. \(2025\)](#) analiza esta evolución a partir de 833 publicaciones recopiladas a lo largo de un amplio horizonte temporal, mientras que [Patrick et al. \(2024\)](#), sobre una muestra de 401 documentos publicados entre 2015 y 2024, identifica una transición progresiva hacia enfoques más integrados, dinámicos y orientados a la automatización de las decisiones financieras.

En el ámbito específico de la predicción bursátil, la revisión sistemática de [Mintarya et al. \(2023\)](#), basada en 30 estudios, identifica las redes neuronales como la familia de modelos más utilizada. De acuerdo con la clasificación empleada por los autores, las redes neuronales convencionales representan el 46.3% de los enfoques analizados, seguidas por las arquitecturas LSTM, con un 19.5%, las máquinas de vectores soporte, con un 17.1%, y otros métodos, con el 17.1% restante. El análisis temporal muestra, además, un aumento del uso de LSTM a partir de 2015, paralelo a una reducción de la presencia de SVM. Las revisiones más recientes confirman esta evolución: LSTM continúa siendo la arquitectura individual de aprendizaje profundo más extendida para el tratamiento de series financieras, mientras que GRU, CNN, SVM, Random Forest y XGBoost aparecen de manera recurrente como métodos alternativos o complementarios ([Aksehir & Kilic, 2024](#); [László Vancsura & Bareith, 2025](#); [Saberironaghi et al., 2025](#)). En consecuencia, aunque no existe un modelo universalmente superior para todos los mercados, horizontes temporales y objetivos de predicción, la literatura evidencia un predominio claro de las redes neuronales recurrentes y, particularmente, de LSTM.

Más allá de la elección de un algoritmo individual, una de las tendencias dominantes es el desplazamiento hacia arquitecturas híbridas y métodos de ensamblado. Estas propuestas combinan modelos de aprendizaje automático y profundo, técnicas de descomposición y reducción de ruido, mecanismos de atención y diferentes clases de información financiera. En particular, se observa una incorporación creciente de datos heterogéneos (precios históricos, indicadores técnicos y fundamentales, noticias y publicaciones en redes sociales) mediante técnicas de procesamiento del lenguaje natural y análisis de sentimiento ([Mohamad et al., 2025](#); [Saberironaghi et al., 2025](#)). La finalidad de esta integración es aprovechar la complementariedad entre las distintas fuentes de información y mejorar la capacidad de los modelos para representar re-

laciones no lineales, dependencias temporales y cambios en el comportamiento del mercado.

En el ámbito de la gestión de carteras, las revisiones recientes destacan el papel emergente del aprendizaje por refuerzo y del aprendizaje por refuerzo profundo en la asignación dinámica de activos, el rebalanceo de carteras y la adaptación de las estrategias a cambios en las condiciones del mercado ([Kumari, 2024](#); [Patrick et al., 2024](#)). Esta línea se relaciona con una tendencia más amplia hacia sistemas de inversión parcialmente autónomos, capaces de actualizar sus decisiones mediante información en tiempo real y de integrar simultáneamente objetivos de rentabilidad, riesgo y preferencias del inversor. En los sistemas de recomendación de productos financieros, la investigación se orienta, asimismo, hacia la integración de información multidominio y sensible al tiempo, así como hacia modelos multicomportamiento y multitarea que consideren conjuntamente las distintas interacciones del usuario y los diferentes objetivos de recomendación ([Wu & Li, 2025](#)). En este contexto, las redes multicapa y los autoencoders se emplean habitualmente para representar información estructurada, mientras que las redes recurrentes resultan especialmente adecuadas para modelar secuencias de comportamiento y series temporales.

No obstante, los trabajos científicos continúan presentando una elevada heterogeneidad en cuanto a conjuntos de datos, horizontes temporales, variables de entrada, objetivos predictivos y métricas de evaluación. Asimismo, numerosos trabajos evalúan la precisión estadística de los modelos sin integrarlos en estrategias reales o simuladas de inversión, y son todavía limitados los análisis de robustez temporal en diferentes regímenes de mercado ([László Vancsura & Bareith, 2025](#); [Saberironaghi et al., 2025](#)). Estas limitaciones dificultan la comparación directa de los resultados.

El punto de partida de muchos de los trabajos en gestión cuantitativa de carteras es el modelo media-varianza de [Markowitz \(1952\)](#), que formaliza el equilibrio entre rentabilidad esperada y riesgo como problema de optimización cuadrática. [Mendizábal Zubeldia et al. \(2002\)](#) constituyen un ejemplo representativo de la aplicación de este marco al mercado español: a partir de los precios diarios de cierre de 30 empresas del IBEX-35 durante los años 2000 y 2001, resolvieron el problema de minimizar la varianza de la cartera sujeto a una restricción de rentabilidad mínima. Los resultados, comparados con los índices IBEX-35 e IGBM, arrojaron una rentabilidad semanal aproximada del 0.8% según la métrica del ratio de Sharpe corregido, demostrando que es posible construir carteras más eficientes que los índices de referencia, aunque con li-

mitaciones derivadas de la concentración y la dependencia de supuestos históricos. De forma complementaria, [García Mazo \(2025\)](#) aplicó un enfoque similar en el mercado colombiano, utilizando cinco activos (cuatro de renta variable y uno de renta fija) con valores diarios de cierre entre 2015 y 2023. En este caso, se empleó regresión LASSO para seleccionar los activos más relevantes y, posteriormente, simulación Monte Carlo para identificar la frontera eficiente, obteniendo carteras con perfiles de rentabilidad y riesgo competitivos.

Con la incorporación de técnicas de aprendizaje automático, varios trabajos han extendido el marco clásico. [Serrano Checca et al. \(2024\)](#) tomaron datos de activos de carteras de fondos de inversión gestionados en cuatro países de América Latina, con datos diarios entre 2013 y 2022. El dataset incluyó precios de acciones y bonos junto con información sobre tipos de cambio, variables macroeconómicas y tamaño de las empresas, entre otros factores. Mediante regresión múltiple evaluaron el rendimiento de las carteras considerando variables como el tamaño de la empresa, la relación precio-beneficio, el crecimiento de los beneficios y la presencia de inteligencia artificial, obteniendo un incremento cercano al 27.5% en el rendimiento ajustado al riesgo medido por el ratio de Sharpe. [Boloş et al. \(2025\)](#) analizaron 294 empresas del S&P 500, utilizando precios de cierre diarios entre 2012 y 2022, junto con métricas de rentabilidad, liquidez y solvencia. Se empleó clustering k-means para segmentar las empresas en grupos diferenciados por perfil de riesgo-rentabilidad y, a partir de las agrupaciones obtenidas, conformaron carteras con menor correlación intraclúster. Las carteras resultantes alcanzaron rentabilidades de hasta un 46.85% con un ratio de Sharpe de 1.17, y un perfil alternativo con un 45.43% de rentabilidad y mejor ajuste de rentabilidad frente al riesgo.

Estos trabajos son directamente relevantes para el presente TFM, que también parte del universo de acciones del S&P 500 y utiliza la capitalización bursátil como criterio de segmentación. En particular, [Switzer \(2010\)](#) documentó diferencias sistemáticas en el comportamiento de acciones de gran capitalización (*large-cap*) frente a las de pequeña capitalización (*small-cap*) a lo largo de ciclos económicos en Estados Unidos y Canadá, evidenciando que ambos segmentos presentan perfiles de riesgo y retorno distintos. Esta distinción justifica el diseño del dataset del presente trabajo, que incluye explícitamente ambas categorías para evaluar si los modelos se comportan de forma diferente según el segmento de capitalización.

Una parte significativa de la literatura se ha centrado en la predicción de precios o retornos como paso previo a la toma de decisiones de inversión. [Seyed Mostafa y Ali Reza \(2025\)](#) utili-

zaron un conjunto de indicadores técnicos como características para el análisis de los precios diarios de cierre del S&P 500, integrando PCA para reducción de dimensionalidad. Se evaluaron modelos como SVR, Random Forest, XGBoost y LSTM mediante una estrategia de ventana rodante de 60 días, y el modelo LSTM mostró un mejor desempeño en la captura de patrones temporales y en la reducción del error frente a los demás métodos. [Vásquez Sáenz et al. \(2023\)](#) evaluaron el rendimiento de modelos de forecasting para la predicción de precios de cierre diarios de 240 compañías del índice Russell 3000, combinando distintas estrategias de clusterización (K-means con DTW, distancia euclídea y EROS) con modelos ARIMA y LSTM. Los resultados pusieron de manifiesto que los modelos basados en redes neuronales pueden superar los enfoques tradicionales y mejorar su rendimiento cuando los datos se segmentan previamente.

En el ámbito de las señales de trading, [Fonseca et al. \(2021\)](#) utilizaron Support Vector Machines con kernel RBF para generar señales de compra y venta en acciones brasileñas, obteniendo una rentabilidad anualizada superior a la de estrategias de comprar y mantener. [Pagliaro \(2023\)](#) aplicó Extra Trees Classifier a indicadores técnicos en un enfoque multinivel (compra/mantener/venta) sobre 120 empresas de distintos sectores, alcanzando una precisión del 86.1% y rentabilidades acumuladas destacables frente a la estrategia pasiva. [Baguda et al. \(2025\)](#) presentaron un modelo de regresión logística consciente de precios (PALR) con regularización L1, que clasifica dinámicamente si los retornos serán positivos o negativos y demostró robustez incluso en entornos de crisis financiera. [Mcwera y Clement Mba \(2023\)](#) evaluaron clasificadores ensemble heterogéneos para predecir la dirección de los retornos diarios en el sector bancario sudafricano, obteniendo tasas de acierto superiores al 95% con la combinación de SVM, árboles de decisión y KNN. Estos trabajos ilustran que la predicción de la dirección del precio es un problema bien estudiado, pero que sus resultados son difícilmente comparables entre sí por la heterogeneidad de datasets, horizontes temporales y métricas empleadas.

En lo que respecta a los sistemas de recomendación aplicados a la selección de activos financieros, se trata de un enfoque más reciente que constituye el núcleo del presente trabajo. [Sanz-Cruzado Puig et al. \(2024\)](#) contribuyeron con un benchmark exhaustivo que comparó once algoritmos de recomendación sobre el dataset FAR-Trans, que integra precios, transacciones e información de clientes. El estudio constató que los modelos basados en precios (Random Forest, Regresión Lineal, LightGBM) predecían mejor la rentabilidad futura, mientras que los enfoques colaborativos (LightGCN) anticipaban con mayor precisión las preferencias de com-

pra. [Michis \(2022\)](#) propuso el uso de correlaciones parciales multiescala estimadas mediante wavelets para aislar la dependencia de los activos con el índice S&P 500, utilizando posteriormente K-means para segmentar activos según el horizonte temporal y facilitar la diversificación en distintos plazos. [Hanyang et al. \(2024\)](#) propusieron un sistema auto-supervisado que construye representaciones de acciones mediante Graph Attention Networks y GRU, incorporando tanto datos históricos de precios como información textual extraída de noticias y redes sociales, lo que permitió explorar las relaciones entre empresas y obtener mejoras sustanciales en precisión. [Tsai et al. \(2023\)](#) emplearon Random Forest, redes feedforward y un modelo híbrido FinGAT que integra Graph Attention y GRU, confirmando que la combinación de estructuras gráficas y secuenciales permite identificar activos con mayores rendimientos relativos.

En cuanto a la personalización por perfil de inversor, [Leung et al. \(2023\)](#) desarrollaron una plataforma web que presenta un cuestionario al usuario para seleccionar activos atendiendo a sus preferencias, combinando aprendizaje por refuerzo para la recomendación de cartera con un modelo LSTM para la predicción de precios, y logrando retornos anuales superiores al índice S&P 500. [Munki et al. \(2023\)](#) introdujeron el Mean-Variance Efficient Collaborative Filtering, que integra regularización de media-varianza en modelos de factorización y sistemas de recomendación basados en grafos. [Lee et al. \(2024\)](#) presentaron PfoTGNRec, un modelo que combina embeddings dinámicos mediante Temporal Graph Networks con muestreo eficiente de media-varianza, alcanzando mejoras simultáneas en diversificación y rentabilidad sobre datos reales de inversores individuales.

El conjunto de estos trabajos evidencia que los sistemas de recomendación de activos han evolucionado desde enfoques puramente colaborativos hacia arquitecturas híbridas que integran información de precios, grafos de relaciones entre empresas y preferencias del inversor. Sin embargo, la mayoría de los estudios se evalúan sobre datasets propietarios o de acceso restringido, con métricas heterogéneas y sin comparativas directas entre familias de modelos.

A medida que estos sistemas se emplean como apoyo a decisiones de inversión, el rendimiento predictivo deja de ser el único criterio de evaluación: la transparencia y la capacidad de justificar las decisiones se vuelven especialmente relevantes en un ámbito donde la salida del modelo se traduce en decisiones sobre el patrimonio del inversor. La revisión sistemática de [Černevičienė y Kabašinskas \(2024\)](#), sobre 138 publicaciones de *explainable AI* (XAI) en finanzas, constata que las cajas negras explicadas con mayor frecuencia son las redes neuronales

artificiales, XGBoost y Random Forest, y que las técnicas más presentes son la importancia de características, SHAP, los métodos basados en reglas y LIME; además, distingue explícitamente entre métodos *ante-hoc* o intrínsecos, cuya estructura resulta directamente comprensible, y métodos *post-hoc*, que requieren una explicación adicional una vez construido el modelo. Esta distinción se corrobora empíricamente en la revisión de [Weber et al. \(2024\)](#) (60 trabajos seleccionados de un total inicial de 2.022), que clasifica como transparentes las regresiones lineales y logísticas, los árboles, el k -NN y los sistemas de reglas, frente a las técnicas post-hoc como LIME o SHAP. Los autores identifican 26 trabajos con modelos transparentes frente a 32 con explicabilidad post-hoc, y observan un desplazamiento claro hacia estas últimas en los años más recientes, en paralelo al aumento de las redes neuronales complejas. No obstante, disponer de una explicación post-hoc no convierte un modelo de caja negra en interpretable: [Rudin \(2019\)](#) sostiene que una atribución obtenida a posteriori es una aproximación al comportamiento del modelo y no una descripción exacta de su razonamiento, por lo que en decisiones de alto impacto defiende la interpretabilidad intrínseca por diseño (mediante *sparsity*, monotonidad o estructuras basadas en reglas) como criterio para decidir qué componentes de un sistema requieren realmente una caja negra.

Esta necesidad de explicación, trasladada al pipeline propio de una herramienta de recomendación de carteras, adopta formas distintas en cada etapa. En la fase predictiva sobre series temporales, la explicación no se limita a identificar qué variables son relevantes, sino también qué posiciones de la secuencia contribuyen a la predicción. [Freeborough y van Zyl \(2022\)](#) entrenan una RNN, una LSTM y una GRU sobre acciones del S&P 500 y, tras el entrenamiento, aplican cuatro mecanismos complementarios (ablación, permutación, adición de ruido e *Integrated Gradients*) para atribuir importancia a características, observaciones y posiciones temporales. Las redes no se vuelven intrínsecamente transparentes, pero la explicación post-hoc revela diferencias sustanciales en cómo cada arquitectura utiliza la información temporal: la GRU retiene información durante períodos más largos, la LSTM emplea las entradas de forma más selectiva y la RNN muestra una capacidad mucho más limitada para mantener dependencias temporales extensas. En el paso de la predicción a la decisión de cartera, el foco se desplaza de *qué* predice el modelo hacia *por qué* se asigna el capital de un modo concreto. [Sutiene et al. \(2024\)](#), en su revisión del proceso de gestión de carteras, separan explícitamente dos objetos que requieren explicación (la predicción de retornos y la decisión de asignación de activos) y discuten para esta última el uso de SHAP y de modelos *surrogate* (árboles, modelos

lineales, reglas o GAM). Sobre agentes de *reinforcement learning*, [Guan y Liu \(2021\)](#) explican políticas A2C y PPO mediante *Integrated Gradients* y, de forma distintiva, contrastan las atribuciones obtenidas con las de un modelo lineal de referencia (construido en *hindsight* a partir de los retornos realizados); en términos de la taxonomía XAI, ese modelo de referencia puede considerarse intrínsecamente interpretable, mientras que los agentes permanecen como cajas negras explicadas post-hoc. [Cortés et al. \(2024\)](#), por su parte, incorporan una capa de atención entre las variables de entrada y una arquitectura multi-cabeza basada en LSTM, de modo que los pesos de atención (extraíbles tras el entrenamiento) permiten inspeccionar qué variables y momentos priorizan la política de inversión, acercándose a una interpretabilidad incorporada al propio diseño.

Un rasgo recurrente es que la sensibilidad de la optimización de Markowitz a las estimaciones de entrada hace que explicar la predicción no baste: errores relativamente pequeños en los retornos esperados pueden traducirse en variaciones importantes en los pesos finales. Sin embargo, los trabajos que reproducen la secuencia de predicción, selección y optimización rara vez explican la frontera entre activos seleccionados y descartados: [Chaweewanchon y Chaysiri \(2022\)](#) combinan predicción neuronal (LSTM, BiLSTM y CNN-BiLSTM) con preselección de activos y optimización *mean-variance* de Markowitz, y [Martínez-Barbero et al. \(2024\)](#) enlazan predicciones LSTM con *mean-variance* sobre los componentes del EURO STOXX 50, pero en ninguno de los dos casos se incorpora una técnica de explicabilidad sobre la red. El principal hueco identificado no está, por tanto, en la ausencia de técnicas para explicar redes neuronales o carteras por separado, sino en su escasa integración dentro de una misma cadena de decisión: son poco frecuentes los sistemas que mantienen una trazabilidad explícita desde la predicción del retorno hasta la ordenación de activos, su selección y la asignación final de pesos, algo especialmente relevante en herramientas orientadas al usuario final, donde conocer la relevancia de una variable no justifica por sí sola una recomendación de inversión.

La Tabla [2.1](#) recoge una selección de trabajos especialmente próximos al enfoque adoptado en este trabajo, que combina la predicción de precios mediante redes neuronales recurrentes con la optimización de carteras de Markowitz y contempla la explicabilidad del proceso. Se han priorizado, por tanto, las propuestas que emplean arquitecturas recurrentes sobre series de precios, las que enlazan explícitamente la predicción con la optimización media-varianza y las que abordan la interpretabilidad de la decisión, junto con las referencias fundacionales del

marco de optimización y de la segmentación por capitalización.

Cuadro 2.1. *Selección de trabajos representativos del estado del arte.*

Referencia	Modelo	Dataset	Horizonte	Variables	Métricas
Markowitz (1952)	Optimización media-varianza	— (marco teórico)	—	Retornos esperados, covarianzas	Rentabilidad esperada, varianza
Seyed Mostafa & Ali Reza (2025) Freeborough & van Zyl (2022)	SVR, RF, XGBoost, LSTM RNN, LSTM, GRU + XAI post-hoc	S&P 500 (precios diarios) Acciones del S&P 500	1 día (ventana 60d) Diario	Indicadores técnicos + PCA Precios/observaciones y posiciones temporales	RMSE, MAE, R^2 Error de predicción, importancia (abla-ción, permutación, ruido, <i>Integrated Gradients</i>)
Chaweeewanchon & Chaysiri (2022)	LSTM, BiLSTM, CNN-BiLSTM + Markowitz MV	SET50 (2015–2020)	Diario	Precios + preselección de activos	Sharpe, retorno medio, riesgo
Martínez-Barbero et al. (2024)	LSTM + Markowitz MV	EURO STOXX 50	Diario	Retornos predichos	Retorno, riesgo, Sharpe
Sutiene et al. (2024)	Revisión (SHAP, <i>surrogates</i>)	— (revisión)	—	Predicción de retornos y asignación de activos	— (explicabilidad del proceso)
Switzer (2010)	Análisis empírico por capitalización	Acciones EE.UU. y Canadá	Ciclos económicos	Retornos <i>large-cap</i> vs. <i>small-cap</i>	Retorno, riesgo por segmento

2.3. Conclusiones sobre el estado del arte

La revisión realizada muestra varias tendencias comunes. Desde 2015, las redes recurrentes, especialmente LSTM y GRU, se han consolidado como arquitecturas de referencia para series financieras. A ellas se suman modelos híbridos que incorporan mecanismos de atención, grafos y fuentes de información heterogéneas. Paralelamente, el campo ha evolucionado desde la predicción de precios hacia la gestión activa de carteras, con aportaciones recientes basadas en aprendizaje por refuerzo y sistemas de recomendación con grafos temporales.

Sin embargo, la literatura presenta una notable fragmentación metodológica. Los trabajos difieren en datasets, horizontes, variables, objetivos y métricas, lo que dificulta la comparación, reproducción e integración de resultados. Además, muchos estudios evalúan la precisión predictiva de forma aislada, sin trasladar las predicciones a estrategias de inversión ni desarrollar herramientas que cubran el proceso completo desde los datos hasta la decisión.

De esta revisión se extraen varios aspectos relevantes para este trabajo: integrar predicción y optimización de cartera en un mismo flujo, combinar redes recurrentes con el modelo de Markowitz, garantizar la reproducibilidad y trazabilidad de los experimentos y mejorar la explicabilidad de las decisiones de inversión. Asimismo, la evidencia sobre diferencias entre segmentos de capitalización ([Switzer, 2010](#)) aconseja no tratar de forma homogénea las acciones de gran y pequeña capitalización. Estos elementos orientan el desarrollo presentado en los capítulos siguientes.

3. Objetivos concretos y metodología del trabajo

Una vez definido el contexto y revisado el estado del arte, se establecen los objetivos que orientan el desarrollo del trabajo y la metodología seguida para alcanzarlos. Primero se presenta el objetivo general, seguido de los objetivos específicos que lo concretan. Finalmente, se describe la metodología empleada, desde la revisión bibliográfica hasta la validación del sistema.

3.1. Objetivo general

El objetivo de este trabajo es diseñar, desarrollar y validar una herramienta software para la construcción de carteras de inversión, combinando la predicción del comportamiento futuro de los activos con la optimización de su rentabilidad esperada y riesgo. El sistema cubrirá todo el proceso, desde la obtención y preparación de los datos hasta la generación y evaluación de distintas alternativas de cartera.

La herramienta se considerará satisfactoria si genera recomendaciones de forma consistente y permite evaluar su desempeño sobre un periodo histórico de al menos diez años. Además, se analizará si alguna de las estrategias propuestas obtiene un rendimiento ajustado al riesgo igual o superior al del índice S&P 500, utilizado como referencia de mercado.

3.2. Objetivos específicos

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos.

- Analizar el estado del arte sobre predicción de activos financieros y construcción de carteras para fundamentar las decisiones adoptadas en el desarrollo del trabajo.
- Reunir un conjunto de datos histórico y fiable sobre la evolución de los activos, con la profundidad temporal suficiente para sustentar tanto el análisis como la posterior evaluación.
- Estimar el comportamiento futuro de los activos a partir de su información histórica, de modo que sirva de base para la toma de decisiones de inversión.
- Construir carteras de inversión a partir de dichas estimaciones, buscando un equilibrio

adecuado entre la rentabilidad esperada y el riesgo asumido.

- Ofrecer distintas alternativas de recomendación de cartera, de manera que sea el usuario quien examine cada propuesta y decida cuál se ajusta mejor a sus preferencias.
- Evaluar la calidad de las recomendaciones simulando su comportamiento sobre datos históricos, comprobando que el proceso es correcto y que refleja un escenario de decisión realista.
- Contrastar las recomendaciones frente a un índice de mercado tomado como referencia realista y analizar de forma crítica la validez de los resultados obtenidos.

3.3. Metodología del trabajo

La metodología se articula en las siguientes fases:

1. Revisión del estado del arte, mediante el análisis de la literatura científica y técnica sobre la predicción de series financieras y la construcción de carteras de inversión.
2. Obtención de los datos, recopilando la información histórica sobre la evolución de los activos a partir de las fuentes disponibles.
3. Preparación del conjunto de datos, que comprende la limpieza y la depuración de la información, así como la construcción del conjunto de datos definitivo empleado en el resto del trabajo.
4. Entrenamiento de los modelos de estimación del comportamiento futuro de los activos a partir de los datos preparados.
5. Construcción de las carteras de inversión a partir de las estimaciones obtenidas, generando las distintas alternativas de recomendación.
6. Validación mediante backtesting, simulando el comportamiento de las carteras sobre datos históricos y comprobando la corrección del proceso.
7. Análisis de los resultados, contrastando las recomendaciones con las referencias establecidas y discutiendo de forma crítica su validez, así como las decisiones adoptadas y las posibles líneas de mejora.

4. Identificación de requisitos

Una vez conocidos los objetivos, se identifican los requisitos que el sistema debe satisfacer, tanto desde el punto de vista funcional como no funcional.

En este trabajo no se busca desarrollar una aplicación de usuario final, sino una herramienta orientada a generar recomendaciones de cartera de forma reproducible. Por ello, los requisitos se centran en la corrección de los cálculos financieros, la modularidad del código y la ausencia de filtración de datos futuros, más que en aspectos de usabilidad o de interfaz.

4.1. Requisitos funcionales

Los requisitos funcionales describen las capacidades que el sistema debe proporcionar para cumplir los objetivos del trabajo. Siguen, de forma aproximada, el recorrido del proceso (desde la adquisición y preparación de los datos hasta la generación y evaluación de las carteras) para facilitar el seguimiento de los requerimientos.

RF-01 — Descarga de datos históricos de precios. El sistema debe ser capaz de obtener series temporales de precios de cotización diaria para un conjunto de acciones, así como del índice S&P 500, cubriendo un horizonte temporal de al menos diez años. Los datos deben incluir, como mínimo, el precio de cierre ajustado por dividendos.

RF-02 — Selección del universo de activos. El sistema debe permitir obtener el universo de inversión a partir de una muestra de acciones de gran capitalización (*large-cap*). La selección deberá intentar garantizar una representación sectorial suficiente para permitir la diversificación de carteras.

RF-03 — Limpieza y preprocesamiento de datos. El sistema debe detectar y tratar los valores ausentes, los errores de datos y los eventos corporativos que puedan distorsionar las series temporales. El resultado del preprocesamiento debe ser un conjunto de datos limpio, consistente y listo para el entrenamiento de modelos.

RF-04 — Partición temporal de los datos. El sistema debe implementar una estrategia de partición temporal de los datos que evite por completo la filtración de información futura

(*data leakage*), separando de forma cronológica los subconjuntos empleados para el entrenamiento, la selección del modelo y la evaluación final.

RF-05 — Entrenamiento de modelos de predicción basados en redes neuronales recurrentes.

El sistema debe entrenar uno o varios modelos de predicción del comportamiento futuro de los activos financieros basados en redes neuronales recurrentes, capaces de capturar las dependencias temporales presentes en las series históricas.

RF-06 — Generación de predicciones. A partir de los modelos entrenados, el sistema debe generar predicciones del comportamiento futuro de cada activo del universo de inversión, en el horizonte temporal definido para la construcción de carteras, de forma que sirvan de entrada al proceso de optimización.

RF-07 — Comparación con el índice de mercado como referencia. El sistema debe incorporar el índice S&P 500 como escenario de referencia de mercado frente al cual contrastar las carteras generadas, sobre el mismo periodo de evaluación y con la misma mecánica de valoración, de forma que la comparación sea homogénea. Esta referencia permite situar el rendimiento de las recomendaciones respecto a una estrategia pasiva de mercado y valorar si aportan mejora sobre ella.

RF-08 — Optimización de carteras mediante el modelo de Markowitz. El sistema debe implementar la construcción de carteras de inversión basada en la teoría moderna de carteras de Markowitz ([Markowitz, 1952](#)), utilizando las predicciones como entrada para estimar los retornos esperados. La optimización debe producir una asignación de pesos para cada activo seleccionado.

RF-09 — Alternativas de recomendación configurables. El sistema debe permitir configurar y ejecutar distintas variantes del proceso de recomendación (como el número de activos seleccionados, la estrategia de optimización o el conjunto de variables de entrada empleado), de modo que el usuario disponga de un abanico de alternativas de cartera entre las que examinar y decidir.

RF-10 — Rebalanceo periódico de carteras. El sistema debe implementar un mecanismo de rebalanceo periódico de las carteras durante el periodo de evaluación, actualizando las ponderaciones con una frecuencia coherente con el horizonte de predicción de cada modelo.

RF-11 — Backtesting sobre datos históricos. El sistema debe evaluar el rendimiento de las carteras generadas mediante backtesting sobre el periodo histórico disponible, simulando la toma de decisiones de inversión sin acceso a datos futuros.

RF-12 — Cálculo de métricas de rendimiento financiero. El sistema debe calcular, para cada cartera evaluada, las siguientes métricas de rendimiento ajustado al riesgo:

- Rentabilidad acumulada.
- Ratio de Sharpe.
- Ratio de Sortino.
- Volatilidad anualizada.
- Máximo *drawdown*.

4.2. Requisitos no funcionales

Los requisitos no funcionales establecen las restricciones de calidad, rendimiento y mantenibilidad que debe satisfacer el sistema, con independencia de su funcionalidad específica.

RNF-01 — Reproducibilidad procedimental. El código fuente, la configuración de parámetros y las semillas aleatorias deben estar versionados de forma que, disponiendo de los mismos datos de entrada, cualquier investigador pueda reproducir los resultados obtenidos. Los datos no forman parte del entregable por restricciones de volumen y licencia de las fuentes originales, pero el procedimiento de obtención está documentado y es replicable.

RNF-02 — Modularidad del código. El sistema debe estar organizado en módulos o componentes claramente diferenciados que correspondan a las etapas del proceso: adquisición de datos, preprocesamiento, entrenamiento de modelos, construcción de carteras y evaluación. Esta separación facilita la sustitución o extensión de cualquier componente sin afectar al resto.

RNF-03 — Ejecución local sin dependencias de infraestructura externa. El sistema debe poder ejecutarse íntegramente en un equipo personal convencional, sin requerir desplie-

que en servidores ni contratación de servicios de computación en la nube. Toda la lógica de entrenamiento, backtesting y evaluación se ejecuta como código local.

RNF-04 — Gestión de dependencias y entorno de ejecución. El sistema debe incluir una especificación completa de las dependencias de software necesarias para su ejecución, de forma que pueda ser instalado y ejecutado en un entorno limpio sin ambigüedades.

RNF-05 — Calidad y documentación del código. El código fuente debe estar documentado de forma suficiente para que un lector con conocimientos de Python y aprendizaje automático pueda comprender su funcionamiento sin necesidad de consultar fuentes externas. Las funciones y módulos principales deben incluir docstrings descriptivos.

RNF-06 — Ausencia de filtración de datos futuros. El sistema debe garantizar que en ninguna etapa del proceso (preprocesamiento, normalización, entrenamiento o evaluación) se utiliza información que no estaría disponible en el momento de la toma de decisión simulada. Este requisito es crítico para la validez de los resultados del backtesting.

4.3. Relación entre requisitos y objetivos

A continuación, en la tabla 4.1, se resume la correspondencia entre los requisitos identificados y los objetivos específicos. Los requisitos no funcionales RNF-01 a RNF-06 no se asocian a un objetivo específico concreto, sino que constituyen condiciones transversales de calidad que sustentan la validez del trabajo en su conjunto.

Cuadro 4.1. *Correspondencia entre objetivos específicos y requisitos funcionales.*

Objetivo específico	Requisitos asociados
Analizar el estado del arte	(sin requisito de sistema directo)
Reunir el conjunto de datos histórico	RF-01, RF-02, RF-03, RF-04
Estimar el comportamiento futuro de los activos	RF-05, RF-06
Construir carteras de inversión	RF-08, RF-10
Ofrecer alternativas de recomendación	RF-09
Evaluar la calidad de las recomendaciones	RF-11, RF-12
Contrastar frente a referencias externas	RF-07

5. Descripción de la herramienta de software desarrollada

A partir de los requisitos anteriores se diseña la herramienta para dar soporte a la construcción y evaluación de carteras de inversión. Se detallan el enfoque general adoptado, los módulos que lo componen, el flujo de procesamiento y, de forma transversal, las principales decisiones de diseño.

5.1. Diseño conceptual

El desarrollo combina dos tipos de información de naturaleza distinta y complementaria: la información de mercado (cotizaciones diarias y tipos de cambio) y la información fundamental de las empresas, procedente de sus estados financieros. La primera se obtiene de Yahoo Finance¹ y la segunda de la plataforma TIKR². El universo de estudio se circunscribe a empresas de gran capitalización, con un histórico que abarca aproximadamente dieciséis años. El detalle de las fuentes, el periodo cubierto y el proceso de selección de la muestra se desarrolla más adelante, en el módulo de adquisición y preparación de datos (5.2).

En el plano técnico, la herramienta se apoya en el ecosistema de Python. La orquestación del flujo de trabajo recae en Kedro³, que aporta un catálogo de datos declarativo, la construcción automática del grafo de dependencias entre etapas y una estructura estandarizada de proyecto. Con ello se favorece la reproducibilidad de los resultados (RNF-01), la gestión de dependencias entre etapas (RNF-04) y una organización modular que permite sustituir o extender cualquier componente sin afectar al resto del sistema (RNF-02). El modelado predictivo se apoya en PyTorch y la optimización de carteras en cvxpy, y el entrenamiento de los modelos aprovecha, además, la aceleración por GPU.

Conviene subrayar, antes de descender al detalle, que el flujo de trabajo no es enteramente automático: incorpora la participación del estudiante en varias de sus etapas, y esta intervención se manifiesta de dos maneras concretas. Por un lado, la adquisición de los estados financieros se llevó a cabo de forma manual, exportándolos individualmente desde la plataforma de origen, sin recurrir a técnicas de extracción automática. Esta es una limitación impuesta por

¹ <https://finance.yahoo.com>

² <https://tikr.com>

³ <https://docs.kedro.org>

las condiciones de la fuente, que condiciona a su vez el volumen de datos que resultó viable reunir. Por otro lado, la calibración de la muestra siguió un proceso iterativo en el que se fue ampliando debido a carencias identificadas desde el primer momento. Debido a restricciones de tiempo, se optó por detener dicha ampliación de los datos y avanzar con la construcción del pipeline y la preparación de los conjuntos de entrenamiento, asumiendo la cobertura alcanzada como suficiente para los objetivos del trabajo. El sistema resultante es, en consecuencia, una herramienta conducida por un usuario y no un servicio autónomo de extremo a extremo.

Con esos recursos como punto de partida, la herramienta articula su funcionamiento en cuatro etapas conceptuales encadenadas que se presentan a continuación.

En la primera, los datos brutos se procesan y consolidan para construir los conjuntos que alimentan el modelo. En este punto el usuario puede escoger entre un conjunto de datos basado únicamente en información de mercado, que denominamos conjunto market, y un conjunto de datos enriquecido con información de estados financieros, denominado conjunto enriched. Esto permite estudiar en qué medida los datos financieros aportan capacidad predictiva.

En la siguiente etapa se entrena un modelo de predicción de retornos que, dentro del alcance de este trabajo, es único y global: un solo modelo por horizonte de predicción atiende a todas las empresas de todos los sectores e incorpora el sector como una variable más de entrada, en lugar de entrenar un modelo especializado por sector.

En la tercera etapa, las predicciones de retorno se utilizan para seleccionar una cantidad K de activos más prometedores. Este parámetro constituye una primera palanca de decisión en manos del usuario, pues un valor de K elevado da lugar a carteras más diversificadas, mientras que un K reducido concentra la inversión en las previsiones de mayor convicción del modelo.

En la cuarta y última etapa, sobre esos K activos se resuelve un problema de optimización de Markowitz que produce la asignación final de pesos, y que puede plantearse bajo varias estrategias y variantes de construcción de cartera, detalladas en el módulo correspondiente (5.5).


Estas cuatro etapas conceptuales se materializan, en la implementación, en un pipeline de datos organizado en fases secuenciales más finas: ingesta de datos, transformación y limpieza, consolidación, preparación para el modelo, modelado y evaluación, y generación de informes.

La Figura 5.1 muestra este flujo completo, las dependencias entre fases y la etapa a la que pertenece cada una.

Por último, el diseño de la herramienta incorpora, la explicabilidad de las decisiones de inversión como una dimensión adicional a la generación de las carteras. Puesto que el sistema produce, para cada estrategia y cada fecha de rebalanceo, una recomendación concreta con su rentabilidad asociada, la interpretación de dichos resultados requiere poder reconstruir la cadena de decisión que los origina. Se pondrá el foco en el retorno estimado por el modelo para cada activo, la posición que ese valor le otorga en la ordenación y que determina su inclusión en el conjunto seleccionado, y el peso final que la optimización le asigna en función del retorno esperado, el riesgo y las covarianzas entre activos.

Con este fin, la herramienta contempla un estudio de explicabilidad acotado, adaptado a la naturaleza de cada etapa. Las fases cuya estructura es transparente por construcción (la selección de activos y la optimización de Markowitz) se prestan a una interpretación directa a partir de sus propias reglas, mientras que para la predicción mediante la red recurrente, único componente opaco del sistema, se recurre a una técnica post-hoc que permite estimar la contribución de cada variable a la estimación resultante.

Figura 5.1. Diagrama del flujo general del sistema.



5.2. Módulo de adquisición y preparación de datos

El universo de inversión comprende acciones de empresas de gran capitalización (large-cap) clasificadas en los 11 sectores del estándar GICS (Global Industry Classification Standard). Aunque el diseño del sistema contempla la incorporación de acciones de pequeña capitalización (small-cap) como segmento diferenciado, el alcance del presente trabajo se limita al segmento large-cap por restricciones de tiempo y disponibilidad de datos. Los datos proceden de dos fuentes principales:

- **TIKR:** estados financieros históricos (cuenta de resultados, flujo de caja, ratios) obtenidos mediante suscripción de pago a la plataforma, que permite exportar los datos en formato Excel y HTML.
- **Yahoo Finance:** precios de cotización diaria ajustados y tipos de cambio entre divisas, descargados mediante la librería `yfinance`.

El periodo histórico cubierto abarca desde enero de 2009 hasta diciembre de 2024, lo que proporciona 16 años de datos diarios de precios y estados financieros anuales.

5.2.1. Muestreo estratificado

Para seleccionar un subconjunto representativo del universo de activos, el sistema implementa un muestreo aleatorio estratificado por sector. Los 11 sectores GICS constituyen los estratos de la muestra. El enfoque inicial preveía calcular el tamaño de muestra por estrato mediante la fórmula estadística para proporciones con nivel de confianza del 95% y margen de error del 5%. Sin embargo, la calidad y disponibilidad irregular de los datos financieros hizo necesario reducir las muestras de estudio para poder avanzar con el desarrollo del trabajo.

El proceso de calibración de la muestra se ejecutó de forma iterativa: se seleccionó una muestra inicial, se verificó la cobertura de datos disponible (estados financieros con cuenta de resultados, flujo de caja y ratios completos), y se amplió en una segunda iteración. Tras dos ciclos de ampliación se detuvo el proceso, asumiendo la cobertura obtenida como suficiente para los objetivos del trabajo, aun cuando no se alcanzó la significación estadística inicialmente prevista.

5.2.2. Normalización de divisas

Dado que el universo de activos es internacional y multdivisa, el sistema normaliza todos los precios a euros (EUR) mediante tipos de cambio diarios descargados de Yahoo Finance. La conversión se realiza con carácter histórico: para cada fecha de cotización, se utiliza el tipo de cambio correspondiente a esa misma fecha (o el más reciente anterior disponible, mediante estrategia backward). Este enfoque permite capturar el efecto real que los movimientos de divisas tuvieron sobre la rentabilidad expresada en euros, reflejando fielmente las condiciones de mercado en cada momento.

Se cubren 10 pares de divisas (USD/EUR, GBP/EUR, JPY/EUR, entre otros) para garantizar la homogeneidad de las series. Los activos cuya divisa no dispone de par de conversión o presentan huecos en los tipos de cambio se colocan en cuarentena y se excluyen del análisis posterior.

5.2.3. Limpieza y preprocesamiento

El módulo de limpieza aplica las siguientes transformaciones sobre los datos brutos:

- **Adecuación de los estados financieros a un formato tabular:** los estados financieros se exportan en formato excel orientado a la lectura humana, no apto para el procesamiento directo. Este paso los reestructura en una tabla analítica, con cada fecha como observación y cada métrica como variable, y selecciona de cada estado (cuenta de resultados, flujo de caja y ratios) únicamente los campos de interés para el modelo, definidos mediante una configuración parametrizable.
- **Descarte de datos anteriores a 2009:** se eliminan los registros financieros con fecha anterior al 1 de enero de 2009, ya que la cobertura uniforme de datos comienza a partir de esa fecha.
- **Conservación de las fechas de publicación reales:** cada estado financiero se mantiene con la fecha en la que la empresa publicó sus resultados, tal como la registra la plataforma de origen. Las distintas empresas publican en distintos momentos del año, y esa fecha real de publicación es la que se asume como fecha de disponibilidad de la información (véase la Sección 5.3).

- **Detección y cuarentena de activos con discrepancias de moneda:** si la divisa reportada por Yahoo Finance para un activo no coincide con la esperada según los estados financieros, el activo se pone en cuarentena.
- **Imputación de valores ausentes:** los huecos se completan siempre a partir de información ya conocida hasta cada instante, sin emplear en ningún caso valores posteriores para rellenar fechas anteriores, de modo que la imputación no introduce información del futuro. Para las series de precios se aplica forward-fill (el último precio conocido se arrastra hacia delante hasta la siguiente cotización). Para los campos financieros se aplica primero una interpolación lineal, que rellena únicamente los huecos internos situados entre dos valores reales conocidos, y a continuación un forward-fill que cubre los huecos finales de la serie (aquellos que no tienen un valor posterior de referencia). En ambos casos la imputación se realiza de forma independiente por activo y en orden cronológico.

Un caso que merece tratamiento propio dentro de esta fase es el de las series de precios. Durante la validación del sistema se detectó que las descargadas de Yahoo Finance contienen, para un pequeño subconjunto de activos, valores sospechosamente anómalos: saltos de precio de uno o dos órdenes de magnitud entre sesiones consecutivas (por ejemplo, divisiones inversas de acciones mal aplicadas), cotizaciones nulas, y penny stocks, acciones con valores por debajo de un euro cuya microestructura genera retornos relativos poco fiables. Estos artefactos no reflejan movimientos reales de mercado y contaminan tanto la variable objetivo del modelo (que se calcula sobre el retorno del precio) como la matriz de covarianza empleada en la optimización de carteras. La descarga se solicita ya con las mejores opciones que ofrece la fuente (ajuste automático por splits y dividendos y reparación de errores conocidos), pero estas no bastan para depurar los activos con datos genuinamente corruptos. Sobre las series así obtenidas, el sistema aplica tres medidas complementarias propias para mitigar los artefactos residuales:

- **Descarte de activos con cotizaciones inválidas (penny stocks):** tras la conversión a EUR, se coloca en cuarentena y se excluye del universo de modelado a cualquier activo con algún precio igual o inferior a un céntimo de euro o cuyo precio mediano sea inferior a un euro (penny stock). El descarte es de la empresa completa, no de observaciones sueltas, ya que la serie de una acción que cotiza en fracciones de céntimo es poco fiable en

su conjunto: su microestructura (el tick mínimo) genera retornos relativos enormes que no son operables en la práctica. Estos umbrales son parametrizables. Sobre la muestra de trabajo, este filtro identifica 9 activos (entre ellos los casos más severos detectados durante la validación, con precios medianos de fracciones de céntimo y saltos de más del 35 000 % en retornos).

- **Recorte (winsorización) de retornos desorbitados:** los saltos que sobreviven al descarte de activos se acotan mediante un recorte de los log-retornos. El límite se fija en un valor diario (por defecto, un log-retorno absoluto de 0,40, equivalente a aproximadamente +49 %/−33 % en un día) y se escala con el horizonte de cada retorno, ya que los log-retornos se acumulan de forma aditiva: un retorno a N sesiones admite N veces el límite diario. De este modo se recortan los saltos en tramos cortos de tiempo sin penalizar las tendencias legítimas a largo plazo. El recorte se aplica tanto a las features de retorno como a la variable objetivo.
- **Cuarentena de ventanas temporales con retornos anómalos:** un penny stock barato puede revalorizarse de forma legítima, por lo que una variación elevada en los retornos no implica necesariamente un error de datos. Descartar una empresa entera por esta razón sería, en consecuencia, demasiado agresivo. La estrategia adoptada es mantener la empresa en el universo y descartar únicamente las ventanas temporales que contengan algún retorno anómalo, evitando así que esos valores contaminen el aprendizaje.

La anomalía se define por sector mediante las vallas de Tukey del log-retorno diario, utilizando el rango intercuartílico (IQR, la diferencia entre el cuartil 3 (Q_3) que indica dónde corta el 75% de los datos y el cuartil 1 (Q_1), que indica dónde corta el 25% de los datos) y un factor de escalado z , quedando el intervalo de valores no anómalos como $[Q_1 - z \cdot \text{IQR}, Q_3 + z \cdot \text{IQR}]$ con $z = 5$. Este umbral se autoajusta a la volatilidad típica de cada sector (más estrecho en Utilities, más amplio en Energy o Healthcare) sin necesidad de recalibrarlo entre horizontes. Los cuantiles se estiman sobre el log-retorno diario crudo, reconstruido directamente a partir del precio en euros y sin aplicarle el recorte de la medida anterior, de modo que la winsorización previa no enmascare los saltos que precisamente se pretende detectar. Así, una ventana se descarta si cualquiera de sus sesiones de entrada o su etiqueta cae fuera de las vallas de su sector.

Se toman dos decisiones para preservar la validez del procedimiento. Primera, los um-

brales se estiman solo con los conjuntos de entrenamiento y validación, nunca con el de test, para no introducir información del futuro en la etapa de preparación. Segunda, el filtrado se aplica solo a las ventanas de entrenamiento y validación: las de test se conservan intactas, ya que sus retornos elevados se analizan durante el backtesting, donde, de ser reales, resultan informativos.

Estas tres medidas actúan de forma escalonada como red de seguridad: en los activos con datos genuinamente corruptos persisten, tras la descarga depurada de la fuente, saltos internos de gran magnitud que solo se neutralizan combinando el descarte de activos, el recorte de retornos y la cuarentena de ventanas.

5.3. Módulo de consolidación e ingeniería de características

Llegados a este punto, el módulo de adquisición y preparación ha producido dos conjuntos de datos independientes y ya normalizados: por un lado, las series de precios de cierre diarios convertidos a euros y, por otro, los estados financieros de las empresas, también expresados en euros. Ambos conviven todavía por separado y con granularidades temporales distintas (los precios son diarios y los estados financieros se publican de forma anual), por lo que aún no constituyen una vista única sobre la que entrenar el modelo.

Este módulo los une en un dataset unificado por sector, deriva a partir de él las métricas y variables que emplea el modelo, y transforma el resultado en las estructuras que consumen las redes neuronales recurrentes. El proceso encadena la construcción del dataset de empresa (que resuelve precisamente esa unión de precios y fundamentales), el cálculo de ratios y log-retornos, la generación de los conjuntos de features, su escalado, la partición temporal y la construcción de ventanas.

5.3.1. Construcción del dataset de empresa

Para cada sector, el sistema realiza un join asof entre los precios diarios y los estados financieros: cada día de precio hereda los fundamentales del último estado financiero publicado en una fecha anterior o igual a la de la observación (estrategia backward). La fecha asociada a cada estado financiero es la de su publicación por parte de la empresa, tal como la registra la plata-

forma de origen (no la del cierre contable del periodo), de modo que cada empresa aporta su información en el momento en que realmente la hizo pública.

Los campos extraídos de los estados financieros se detallan en la Tabla 5.1. Todos ellos se obtienen de la plataforma TIKR y corresponden a datos anuales.

Cuadro 5.1. Campos extraídos de los estados financieros.

Hoja	Campo	Descripción
Income Statement	Total Revenues	Ingresos procedentes de la venta de productos y servicios.
Income Statement	Cost of Goods Sold	Coste total de fabricar y entregar el producto o servicio.
Income Statement	Gross Profit	Beneficio bruto: ingresos totales menos coste de los bienes vendidos.
Income Statement	Total Operating Expenses	Suma de todos los gastos operativos, incluyendo amortización y depreciación.
Income Statement	Operating Income	Beneficio operativo: beneficio bruto menos gastos operativos totales.
Income Statement	EBITDA	Beneficio antes de intereses, impuestos, depreciación y amortización.
Income Statement	Net Income to Company	Beneficio neto atribuible a la empresa.
Income Statement	Weighted Avg. Diluted Shares	Promedio ponderado de acciones diluidas en circulación.
Cash Flow	Free Cash Flow	Flujo de caja libre disponible tras inversiones operativas.

Fuente: TIKR.

5.3.2. Métricas derivadas y notación temporal

Sobre el dataset consolidado se calculan dos familias de métricas que no están disponibles directamente en las fuentes: los ratios de rentabilidad y los log-retornos. La primera familia son cuatro ratios de rentabilidad, obtenidos a partir de los campos de la cuenta de resultados, que normalizan las magnitudes respecto a la facturación y permiten comparar empresas de distinto tamaño en una escala común:

- Margen bruto: $\frac{\text{Gross Profit}}{\text{Total Revenues}}$
- Margen EBITDA: $\frac{\text{EBITDA}}{\text{Total Revenues}}$
- Margen operativo: $\frac{\text{Operating Income}}{\text{Total Revenues}}$
- Margen neto: $\frac{\text{Net Income to Company}}{\text{Total Revenues}}$

La segunda familia son los log-retornos del precio de cierre en euros. Se opta por trabajar con retornos, y no con los precios en bruto, porque el precio por acción no es comparable entre empresas: dos compañías pueden experimentar la misma variación relativa partiendo de precios por acción muy distintos. El retorno expresa esa variación en términos relativos y lleva a una escala común los movimientos de precio de activos con niveles de cotización dispares, lo que es imprescindible para que el modelo aprenda patrones transversales al conjunto de empresas.

Definir estos retornos exige fijar antes una notación temporal, que además se emplea de forma transversal en el resto del capítulo. Consideremos una señal como la información que obtenemos al cierre de una sesión bursátil. Se toma como origen el instante de la señal, t_0 , es decir, ésta es la última sesión bursátil ya cerrada de la que se dispone de información. Se exige, además, que en ese instante exista suficiente historia previa conocida, condición que permite construir las ventanas temporales que se describen más adelante.

A partir de ese origen, t_k denota la sesión situada k posiciones después de la señal (k negativo para las sesiones anteriores y positivo para las posteriores), y p_k es el precio de cierre (en euros) de la sesión t_k . Esta convención, anclada en la última información conocida, permitirá más adelante alinear con rigor la predicción con la recomendación de inversión.

Todo retorno se mide sobre una distancia temporal determinada, el horizonte, que tiene una cantidad h de sesiones. El horizonte condiciona aspectos esenciales del sistema: además de la escala sobre la que se calcula el retorno, determina la variable que el modelo aprende a predecir y la frecuencia de rebalanceo de la cartera. En la tabla 5.2 se presentan los horizontes empleados. La correspondencia entre horizontes temporales y número de sesiones sigue la convención habitual de considerar aproximadamente 252 sesiones de negociación por año (Kirby, 2025; Mancinelli & Oliva, 2023): un mes bursátil se aproxima mediante $252/12 = 21$ sesiones, de modo que los horizontes de 2, 3 y 6 meses corresponden a 42, 63 y 126 sesiones respectivamente, y de forma análoga se consideran 5 sesiones por semana y 10 para dos semanas.

A partir del origen temporal y del horizonte definidos, el log-retorno a h sesiones correspondiente a la sesión t_k se define como

$$r_k^{(h)} = \log\left(\frac{p_k}{p_{k-h}}\right), \quad (5.1)$$

Cuadro 5.2. Horizontes de predicción soportados por el sistema, con su duración en sesiones bursátiles (h).

Horizonte	Sesiones (h)
1 día	1
1 semana	5
2 semanas	10
1 mes	21
2 meses	42
3 meses	63
6 meses	126

esto es, el logaritmo del cociente entre el precio de cierre de la sesión t_k y el de h sesiones antes, que solo se conoce una vez cerrada la sesión t_k . En lo que sigue, el caso diario ($h = 1$) se abrevia $r_k \equiv r_k^{(1)} = \log(p_k/p_{k-1})$. El uso del logaritmo, frente al retorno aritmético, aporta la aditividad temporal (los log-retornos de sesiones consecutivas se suman para dar el del periodo completo) y una distribución más simétrica y estable, propiedades convenientes tanto para el modelado como para el posterior tratamiento de los retornos.

La inclusión de múltiples horizontes permite evaluar si la señal predictiva mejora a horizontes más largos, donde las features fundamentales pueden tener mayor relevancia, y explorar distintas frecuencias de rebalanceo en la construcción de carteras.

5.3.3. Generación de los conjuntos de features

La herramienta contempla dos conjuntos de datos como información de entrada, que responden a dos enfoques sobre qué datos resultan más útiles para anticipar el comportamiento de los activos. El primero, el conjunto market, se apoya exclusivamente en la información de mercado, bajo la premisa de que la propia historia reciente de los retornos contiene la señal relevante.

Cuadro 5.3. Conjunto de características del conjunto market

Feature	Descripción
market_return_{h}	Log-retorno del precio de cierre en EUR a la escala del horizonte del modelo (con sufijo $h \in \{1d, 1w, 2w, 1m, 2m, 3m, 6m, 1y\}$).
sector_ohe_* (11)	Codificación <i>one-hot</i> del sector GICS del activo (11 columnas binarias, una por sector).

El conjunto market, resumido en la Tabla 5.3, describe cada sesión bursátil de un activo mediante dos componentes. La primera es la componente de retorno: dado que cada modelo se

especializa en un horizonte de predicción (Tabla 5.2), se emplea únicamente el log-retorno a la escala la última señal (Ecuación 5.1), es decir, `market_return_1`, que denotamos anteriormente como r_0 .

La segunda componente identifica el sector del activo. Cada empresa pertenece a uno de los $s = 11$ sectores GICS, que se codifica mediante one-hot encoding en un vector binario

$$\mathbf{c} = (c_1, \dots, c_s) \in \{0, 1\}^s, \quad \sum_{i=1}^s c_i = 1, \quad (5.2)$$

donde la única componente igual a 1 señala el sector al que pertenece el activo y el resto son 0. Esta codificación permite que un único modelo global distinga el sector de cada observación sin imponer entre ellos un orden artificial. Al ser indicadores binarios, estas componentes no se someten al escalado robusto que se aplica al resto de variables.

Con ambas componentes, el vector de características del conjunto `market` para una sesión es la concatenación del log-retorno y el vector de sector,

$$\mathbf{x}^{\text{market}} = (r, c_1, \dots, c_s) \in \mathbb{R}^{d_{\text{market}}}, \quad d_{\text{market}} = 1 + s, \quad (5.3)$$

un vector plano de dimensión $d_{\text{market}} = 12$.

El segundo conjunto, `enriched`, extiende el anterior incorporando la información fundamental de las empresas, procedente de sus estados financieros, bajo la premisa de que estos datos aportan contexto adicional sobre la situación de cada compañía, según se detalla en la tabla 5.4.

Las magnitudes financieras absolutas (ingresos, EBITDA, flujo de caja libre, número de acciones, etc.) presentan un problema de escala: sus valores abarcan desde millones hasta cientos de miles de millones de euros, con una distribución de cola muy pesada. Introducir las directamente en el modelo, o incluso someterlas sin más al escalado posterior, dejaría que las empresas mayores dominaran numéricamente el aprendizaje. Para atenuarlo, cada una de estas magnitudes se transforma mediante la función logarítmica con signo

$$\text{slog}(x) = \text{sign}(x) \cdot \log(1 + |x|), \quad (5.4)$$

Cuadro 5.4. *Features adicionales del conjunto enriched sobre las de market (total 26 variables).*

Feature	Descripción
<i>Magnitudes en log-escala con signo:</i>	
fund_revenue_slog	Total Revenues (EUR).
fund_cogs_slog	Cost of Goods Sold (EUR).
fund_gross_profit_slog	Gross Profit (EUR).
fund_opex_slog	Total Operating Expenses (EUR).
fund_operating_income_slog	Operating Income (EUR).
fund_ebitda_slog	EBITDA (EUR).
fund_net_income_slog	Net Income to Company (EUR).
fund_diluted_shares_slog	Weighted Avg. Diluted Shares Outstanding.
fund_free_cash_flow_slog	Free Cash Flow (EUR).
fund_market_cap_slog	Capitalización bursátil (precio de cierre en EUR × acciones diluidas).
<i>Ratios financieros (adimensionales):</i>	
fund_gross_profit_ratio	Margen bruto (Gross Profit / Total Revenues).
fund_ebitda_ratio	Margen EBITDA (EBITDA / Total Revenues).
fund_operating_income_ratio	Margen operativo (Operating Income / Total Revenues).
fund_net_income_ratio	Margen neto (Net Income / Total Revenues).

que comprime el rango de la variable x (una diferencia de varios órdenes de magnitud se convierte en una diferencia moderada) a la vez que conserva el signo (relevante en partidas que pueden ser negativas, como el beneficio o el flujo de caja) y trata el cero de forma continua, sin la singularidad del logaritmo ordinario. Esta transformación es una preparación previa de cada variable por separado; la homogeneización entre variables la realiza después el escalado robusto, como se detalla más adelante. Los ratios de rentabilidad y los log-retornos no requieren esta compresión, pues ya son adimensionales y de rango acotado.

Reuniendo estas variables fundamentales en un vector $\mathbf{f} \in \mathbb{R}^m$ (con m el número de variables fundamentales, las magnitudes en slog y los ratios recogidos en la Tabla 5.4), el vector de características del conjunto enriched para una sesión concatena el vector de market con dicho vector:

$$\mathbf{x}^{\text{enriched}} = (\mathbf{x}^{\text{market}}, f_1, \dots, f_m) \in \mathbb{R}^{d_{\text{enriched}}}, \quad d_{\text{enriched}} = d_{\text{market}} + m, \quad (5.5)$$

de modo que enriched es una extensión de market y comparte con él la misma estructura de vector plano. Este vector de características, en cualquiera de las dos representaciones, es la unidad que, replicada a lo largo de las sesiones de una ventana temporal, conforma la entrada de la red recurrente (Sección 5.3.6).

Frente a este vector de características, que constituye la entrada del modelo, cada observación lleva asociada una variable objetivo y : el log-retorno a horizonte h que el modelo debe predecir. De este modo, la unidad de modelado queda como un par (entrada, objetivo), que se denota como el par $(\mathbf{x}, y)$.

En cuanto a la disponibilidad temporal de estos datos, se asume que cada estado financiero está disponible desde su fecha de publicación, que es la fecha con la que la plataforma de origen lo registra. No se aplica, por tanto, ningún desfase adicional ni se alinean los datos a una fecha común de fin de año: cada empresa publica en su propio calendario y esa fecha real es la que determina desde cuándo el dato puede emplearse como feature. Se reconoce como limitación que, en la práctica, podría existir un pequeño desfase entre la fecha de publicación registrada y el instante exacto en que la información resultó accesible para el mercado.

5.3.4. Escalado robusto

Las features se escalan mediante un preprocesador robusto basado en mediana y rango intercuartílico (IQR), ajustado exclusivamente sobre los datos de entrenamiento. Conviene distinguir aquí entre el ajuste y la aplicación del escalado: los estadísticos (mediana e IQR de cada variable) se estiman únicamente con las filas de entrenamiento, mientras que la transformación resultante se aplica después, con esos mismos estadísticos, a los tres conjuntos (entrenamiento, validación y test). De este modo, los conjuntos de validación y test se escalan con parámetros que no dependen de ellos, lo que evita cualquier fuga de información desde el futuro hacia la etapa de preparación. La transformación aplicada a cada feature x es:

$$x_{\text{scaled}} = \frac{x - \tilde{x}}{\text{IQR}(x)} \quad (5.6)$$

donde $\tilde{x}$ es la mediana y $\text{IQR}(x) = Q_3 - Q_1$ es el rango intercuartílico. Las features binarias (las columnas one-hot de sector) se excluyen del escalado.

El objetivo de este escalado es distinto del de la transformación slog aplicada previamente a las magnitudes financieras. Aquella comprimía el rango dentro de cada variable, para que cifras de miles de millones resultaran manejables; el escalado robusto, en cambio, lleva todas las features a una escala común y centrada en cero, con independencia de su naturaleza (precios,

retornos, ratios o fundamentales ya transformados con slog). Este paso es necesario porque las variables de entrada conviven en magnitudes muy dispares, y sin homogeneizarlas la red tendería a dejarse dominar por las de mayor escala. En la transformación, la mediana centra los datos y el IQR fija la dispersión.

La elección de la mediana y el IQR, frente a la estandarización clásica por media (μ) y desviación típica (σ), es precisamente lo que dota al escalado de resistencia frente a valores extremos: la mediana no se desplaza por outliers puntuales, y el IQR mide la dispersión del 50% central de los datos, ignorando las colas. Esta propiedad es especialmente relevante en series financieras, donde eventos de mercado excepcionales pueden generar valores varios órdenes de magnitud fuera del rango habitual.

Por último, sobre los valores ya escalados se aplica un recorte (clipping) que los acota a un intervalo fijo en torno a cero. No debe confundirse con la winsorización de log-retornos descrita en la limpieza de las series de precios (Sección 5.2.3): aquella actuaba antes del escalado, sobre los retornos en su escala natural, para eliminar saltos corruptos de la fuente; este recorte actúa después del escalado, sobre todas las features y en la escala ya estandarizada, y funciona como una última red de seguridad frente a los valores extremos residuales que hayan podido escapar a las etapas anteriores.

5.3.5. Partición temporal

Los datos se dividen cronológicamente en tres particiones sin solapamiento, cuyas características se resumen en la Tabla 5.5.

Cuadro 5.5. *Partición temporal de los datos.*

Partición	Periodo	Duración	Uso
Entrenamiento	01/01/2009 – 31/12/2019	11 años	Ajuste de pesos del modelo
Validación	01/01/2020 – 31/12/2021	2 años	Selección de modelo, early stopping
Test	01/01/2022 – 31/12/2024	3 años	Evaluación final (backtesting)

Esta partición se ha dimensionado para garantizar que incluso el horizonte de predicción más largo (6 meses, 126 sesiones) disponga de suficientes datos con target calculable en el periodo de validación. La partición garantiza que no existe filtración de información futura (data leakage), ya que cada partición es estrictamente posterior a la anterior. Además, se implementa una lógica de elegibilidad por muestra (sample eligibility) que excluye las observaciones situadas en

las fronteras entre particiones cuyo target cruzaría al periodo siguiente.

5.3.6. Ventanas temporales

Para alimentar los modelos recurrentes se prepara una secuencia de sesiones consecutivas, la ventana temporal, que proporciona a la red la historia reciente sobre la que basar la predicción. Cada sesión t_k se describe mediante el vector de características $\mathbf{x}_k \in \mathbb{R}^d$ (5.3 y 5.5), donde su componente de retorno es el log-retorno r_k de la sesión y $d \in \{d_{\text{market}}, d_{\text{enriched}}\}$ según el conjunto elegido. Siendo ℓ la longitud de la ventana, la entrada al modelo es la secuencia de los ℓ vectores más recientes, que terminan en la sesión de señal t_0 , apilados por filas:

$$\mathbf{X} = [\mathbf{x}_{-\ell+1}; \mathbf{x}_{-\ell+2}; \dots; \mathbf{x}_0] \in \mathbb{R}^{\ell \times d}, \quad (5.7)$$

donde el punto y coma denota apilamiento por filas, de modo que la fila k -ésima de $\mathbf{X}$ es el vector $\mathbf{x}_k$ y la última fila, $\mathbf{x}_0$, incorpora el último retorno conocido en el instante de la señal, $r_0 = \log(p_0/p_{-1})$. La ventana se desliza sesión a sesión a lo largo de la serie, de modo que cada posición genera una muestra de entrenamiento distinta.

La longitud ℓ fija cuánta historia reciente observa la red en cada predicción. Se ha adoptado $\ell = 20$ sesiones (aproximadamente un mes bursátil), un valor habitual en la literatura de predicción de series financieras con redes recurrentes: [Zheng et al. \(2021\)](#) emplean ventanas de 20 sesiones para predecir la observación inmediatamente posterior; [Petrozziello et al. \(2022\)](#) adoptan igualmente ese tamaño de ventana; y [Ko y Chang \(2021\)](#) lo contemplan entre las longitudes evaluadas, obteniendo con él su mejor rendimiento en la mayoría de los casos analizados. Esta elección equilibra el aportar suficiente contexto temporal a la red y el no diluir la señal reciente con historia demasiado antigua.


Una vez construida la ventana, resta precisar cómo se define el target y cómo se alinea con una decisión de inversión realista. La fecha en la que se dispone de la información no coincide con la fecha en la que se puede actuar sobre ella: una señal calculada con el cierre de la sesión t_0 no puede ejecutarse a ese mismo cierre, sino, como pronto, en la sesión siguiente. Para reflejar esta restricción operativa se introduce un desfase de ejecución (execution lag) de L sesiones entre la señal y la entrada efectiva en el mercado, con $L = 1$ en todas las configuraciones, de modo que la operación entra en la sesión t_L . La posición permanece abierta durante el

número de sesiones que fija el horizonte de predicción h (holding period), según la Tabla 5.2 de la Sección 5.3.2, y sale en la sesión t_{L+h} . El target asociado a cada ventana es el log-retorno realizado entre la entrada y la salida de la operación:

$$y_h = \log\left(\frac{p_{L+h}}{p_L}\right). \quad (5.8)$$

El desfase L cumple una doble función: reproduce la latencia real entre la generación de la señal y su ejecución, y garantiza que el retorno objetivo comienza en t_L , una sesión después de la última información empleada.

Figura 5.2. Construcción de las ventanas temporales deslizantes, para el horizonte de 1 día.



La Figura 5.2 ilustra la construcción de una ventana: las $\ell = 20$ sesiones de entrada que terminan en la señal t_0 , el desfase de ejecución L y el periodo de holding sobre el que se define el retorno objetivo, así como el deslizamiento de la ventana a lo largo de la serie.

Se descartan las ventanas que cruzan gaps de calendario superiores a 10 días (indicativos de suspensiones o periodos sin cotización) y, en los conjuntos de entrenamiento y validación, las que contienen algún retorno anómalo según el criterio, para cada sector, descrito en la Sección 5.2.3. El descarte de una ventana no altera la longitud ni la continuidad de las demás: cada ventana se genera de forma independiente recorriendo las posiciones de la serie, por lo que omitir una no deja huecos en las vecinas.

5.4. Módulo de predicción de precios

El problema que resuelve el modelo se apoya en la notación y las magnitudes ya introducidas al describir las ventanas temporales (Sección 5.3.6): la ventana de entrada $\mathbf{X}$ (Ecuación 5.7), que recoge los ℓ log-retornos más recientes hasta la sesión de señal t_0 junto con el sector y , en su caso, las variables fundamentales; y la variable objetivo y_h (5.8), el log-retorno realizado entre la entrada t_L y la salida t_{L+h} . En términos de esas magnitudes, el modelo aprende una función que estima el retorno objetivo a partir de la ventana de entrada.

Denotando por g_θ la red recurrente con parámetros θ , la predicción es

$$\hat{y} = g_\theta(\mathbf{X}) \approx y. \quad (5.9)$$

Se entrena un modelo independiente por cada horizonte h y por cada conjunto de variables (market o enriched); la Ecuación 5.7 determina la dimensión de entrada d en cada caso.

5.4.1. Arquitectura del modelo predictivo

El módulo de predicción implementa una red neuronal recurrente genérica (RecurrentRegressor) parametrizable, capaz de instanciarse con tres variantes de celda: RNN básica (Elman), GRU (Gated Recurrent Unit) y LSTM (Long Short-Term Memory), en configuración unidireccional o bidireccional. Sobre las capas recurrentes se dispone una cabeza de regresión (multilayer perceptron) que proyecta el último estado oculto a una salida escalar: el log-retorno predicho para el horizonte correspondiente.

En lugar de fijar una arquitectura concreta a priori, el tipo de celda y sus dimensiones no se establecen manualmente, sino que se determinan mediante un proceso de optimización de hiperparámetros (descrito más adelante). Los grados de libertad de la arquitectura son:

- **Tipo de celda recurrente:** {RNN, GRU, LSTM}.
- **Direccionalidad:** unidireccional o bidireccional.
- **Tamaño del estado oculto:** {32, 64, 128, 256} unidades.
- **Número de capas recurrentes:** entre 1 y 10.

- **Dropout recurrente:** entre 0,0 y 0,4.
- **Cabeza de regresión:** tamaño de la capa oculta {16, 32, 64}, función de activación {ReLU, SiLU, LeakyReLU, GELU, lineal} y dropout entre 0,0 y 0,5.

La configuración base de referencia (punto de partida antes de la búsqueda) es una GRU unidireccional de 2 capas con 64 unidades ocultas, dropout recurrente del 10%, y una cabeza con capa oculta de 32 unidades, activación ReLU y dropout del 20%.

5.4.2. Entrenamiento

El bucle de entrenamiento incorpora early stopping, un scheduler de reducción de la tasa de aprendizaje y gradient clipping. Los hiperparámetros que no forman parte de la búsqueda se fijan a los siguientes valores base:

- **Optimizador:** Adam.
- **Función de pérdida:** Smooth L1 Loss ($\beta = 1.0$).
- **Gradient clipping:** norma máxima de 1.0.
- **Early stopping:** paciencia de 8 épocas, delta mínimo de 10^{-5} .
- **Learning rate scheduler:** reducción por factor 0.5 con paciencia de 3 épocas, hasta un mínimo de 10^{-6} .
- **Tamaño de lote:** 1024 muestras.
- **Épocas máximas:** 50.

La tasa de aprendizaje y el weight decay no se fijan, sino que se optimizan durante la búsqueda de hiperparámetros. La función Smooth L1 se eligió frente a MSE por su menor sensibilidad a valores extremos, característica deseable en series financieras con colas pesadas.

5.4.3. Optimización de hiperparámetros

En lugar de comparar manualmente un conjunto cerrado de arquitecturas, la selección del modelo se realiza mediante optimización bayesiana de hiperparámetros con Optuna. Se lanza un estudio independiente por cada horizonte de predicción.

Las características del proceso de búsqueda son:

- **Métrica objetivo:** RMSE sobre el conjunto de **validación**, a minimizar. El conjunto de test no interviene en ningún momento de la búsqueda (ni en el ajuste de pesos ni en la selección de configuración), preservando así la evaluación out-of-sample.
- **Muestreador:** TPE (Tree-structured Parzen Estimator), un algoritmo de optimización bayesiana que propone configuraciones prometedoras a partir de los resultados de los trials anteriores.
- **Pruning:** MedianPruner aborta de forma temprana los trials poco prometedores. Cada trial reporta el RMSE de validación por época y se descarta si su rendimiento queda por debajo de la mediana de los trials previos (tras 5 trials de arranque y un mínimo de 3 épocas de margen).
- **Estudios independientes por tipo de dataset:** para cada horizonte se ejecutan dos estudios separados, uno con el conjunto market y otro con el enriched, cada uno con su propio presupuesto de búsqueda y su propio modelo ganador. De este modo se dispone de un modelo para cada representación de los datos, y la elección entre ambas queda a criterio del usuario en lugar de resolverse automáticamente dentro de la búsqueda. Esto permite, además, comparar en la fase de evaluación el rendimiento de las carteras construidas con uno y otro conjunto.
- **Presupuesto:** 10 trials por estudio (configurable), con una única semilla por trial (42) para garantizar comparabilidad.
- **Reanudabilidad:** cada estudio se persiste en una base de datos SQLite (`optuna_study.db`), lo que permite retomar la búsqueda sin repetir los trials ya completados. La mejor configuración se guarda en `best_params.json`.

Una vez concluida la búsqueda, la configuración ganadora de cada estudio (la de menor RMSE de validación) se reentrena con múltiples semillas para evaluar la robustez y construir un ensemble promediando las predicciones. Se emplean cinco semillas (11, 23, 42, 71 y 101), de modo que el ensemble final promedia las predicciones de los cinco modelos entrenados con idéntica configuración pero distinta inicialización. Esta fase multi-semilla se aplica después de la búsqueda, sobre la configuración ya seleccionada.

5.4.4. Parada temprana y selección del mejor modelo

Tanto en la búsqueda de hiperparámetros como en el reentrenamiento multi-semilla, cada modelo se entrena con parada temprana (early stopping) para evitar el sobreajuste y acotar el coste de cómputo. El bucle de entrenamiento evalúa, al final de cada época, la pérdida sobre el conjunto de validación y guarda los pesos del modelo (un checkpoint) únicamente cuando dicha pérdida mejora respecto a la mejor observada hasta el momento (con un margen mínimo de 10^{-5}). Si transcurren 8 épocas consecutivas sin mejora, el entrenamiento se detiene y se restaura el checkpoint de la mejor época, que es el que se emplea para la inferencia. De forma complementaria, un planificador de la tasa de aprendizaje (ReduceLROnPlateau) la reduce a la mitad cuando la validación se estanca durante 3 épocas, lo que ayuda a afinar el ajuste en las fases finales.

El historial de entrenamiento por época (pérdida de entrenamiento y de validación, tasa de aprendizaje y época del mejor checkpoint) se persiste para cada semilla, lo que permite reconstruir a posteriori las curvas de aprendizaje y el punto exacto de parada. Estas curvas se muestran, para las configuraciones ganadoras, en el capítulo de evaluación (Sección 6.2.1 y de forma más extendida en 9).

Las métricas concretas con las que se valora la calidad predictiva de los modelos (Information Coefficient, long-short spread, MAE/RMSE, directional accuracy y dispersion ratio) se describen y discuten en el capítulo de evaluación (Sección 6.1.1), donde se presentan sus valores sobre el conjunto de test.

5.5. Módulo de construcción de carteras

El módulo de construcción de carteras transforma las predicciones de retornos generadas por el modelo recurrente en asignaciones de pesos para una cartera de inversión, mediante la resolución de un problema de optimización de tipo Markowitz. El sistema no se limita a una única forma de repartir el capital entre los activos seleccionados, sino que contempla cuatro estrategias de optimización, que se diferencian por su función objetivo y por el papel que otorgan a las predicciones de retorno y al riesgo.

Conviene precisar que, en todas las estrategias, la selección de los activos que componen la cartera parte siempre de las predicciones del modelo: en cada rebalanceo se eligen los K activos con mayor retorno predicho. Lo que distingue a las estrategias es cómo reparten el capital entre esos K activos ya seleccionados. A continuación se describe primero cómo se seleccionan esos K activos, después la notación común empleada en las formulaciones y, por último, cada una de las cuatro estrategias con su problema de optimización completo.

5.5.1. Selección de activos

En cada fecha de rebalanceo, se seleccionan los K activos con mayor retorno predicho. El sistema evalúa cuatro valores de K : 5, 10, 15 y 20 activos, lo que permite analizar el efecto de la concentración de la cartera sobre el rendimiento y el riesgo. Estos K activos son los que reciben peso en la optimización que se describe a continuación.

5.5.2. Notación común

Las cuatro estrategias se plantean sobre los mismos K activos seleccionados y comparten la notación básica siguiente. El vector de pesos es $\mathbf{w} \in \mathbb{R}^K$, con w_i el peso del activo i . Los dos elementos que intervienen en todas las formulaciones son:

- $\boldsymbol{\mu} \in \mathbb{R}^K$: log-retornos esperados de los activos sobre el periodo de holding, tomados directamente de las predicciones del modelo, $\mu_i = \hat{r}_i$, con $\hat{r}_i$ el log-retorno predicho para el activo i . No se anualizan: se trabaja en la escala del periodo de holding, en la que $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ quedan expresados de forma homogénea, evitando mezclar convenios (retorno

simple frente a logarítmico) y horizontes temporales.

- $\Sigma \in \mathbb{R}^{K \times K}$: matriz de covarianza de log-retornos estimada sobre datos históricos diarios y escalada al periodo de holding mediante $\Sigma = \Sigma_{\text{diaria}} \cdot h$, con h el número de sesiones del periodo, bajo el supuesto de log-retornos independientes e idénticamente distribuidos.

Los parámetros propios de cada estrategia ($\sigma_{\text{máx}}$, μ_{obj} y λ) se introducen al presentar la formulación que los emplea.

Todas las estrategias comparten dos restricciones estructurales, presentes en cada formulación: la inversión total del capital ($\sum_i w_i = 1$) y un límite de concentración por activo, $|w_i| \leq w_{\text{máx}}$ con $w_{\text{máx}} = 0,30$, que impide que un solo activo acapare más del 30 % del capital.

A ellas se suma una condición sobre el signo de los pesos que da lugar a las dos variantes en que puede resolverse cada estrategia. La variante long-only prohíbe las posiciones cortas ($w_i \geq 0$): todo el capital se reparte en posiciones compradoras. La variante long-short permite posiciones cortas (pesos negativos, que apuestan a la caída de un activo) acotando la exposición bruta $\|\mathbf{w}\|_1 = \sum_i |w_i| \leq L$, con un apalancamiento máximo $L = 1,5$. En esta última, ambas condiciones actúan a la vez: como los pesos suman la unidad (exposición neta del 100 %) y la exposición bruta no supera 1,5, la suma de posiciones cortas no puede exceder el 25 % del capital y la de largas el 125 %; el límite de las posiciones cortas no es, por tanto, un parámetro independiente, sino que se deriva del apalancamiento máximo. La diferencia práctica entre ambas variantes es, pues, que la long-short dispone de un grado de libertad adicional (poder vender en corto) que le permite, en principio, aprovechar también las predicciones bajistas, a costa de asumir el riesgo asociado al apalancamiento.

Por concisión, cada estrategia se enuncia a continuación únicamente en su forma long-only; la variante long-short se obtiene sustituyendo la restricción $0 \leq w_i \leq w_{\text{máx}}$ por $|w_i| \leq w_{\text{máx}}$ y añadiendo la restricción de apalancamiento $\sum_{i=1}^K |w_i| \leq L$, manteniendo la inversión total.

En lo que sigue, la resolución de cada problema se realiza mediante el solucionador convexo `cvxpy` con `OSQP` como solver principal y `SCS` como alternativa; si un problema resulta infactible, se aplica un fallback a pesos equiponderados ($w_i = 1/K$).

5.5.3. Estrategia de máximo retorno

La estrategia de máximo retorno (max_return) maximiza el retorno esperado de la cartera sujeto a un techo de riesgo. Acota la volatilidad, pero no persigue la diversificación como objetivo explícito, por lo que constituye la formulación de referencia frente a la que se comparan las demás. El techo de riesgo se controla con el parámetro $\sigma_{\text{máx}} = 0,20$, la volatilidad máxima permitida de la cartera, que se configura como volatilidad anual (parámetro intuitivo y comparable entre horizontes) y se convierte internamente a la escala del periodo mediante $\sigma_{\text{máx}}^{\text{periodo}} = \sigma_{\text{máx}} \cdot \sqrt{h/252}$. El problema, en su variante long-only, es:

$$\begin{aligned} & \underset{\mathbf{w} \in \mathbb{R}^K}{\text{máx}} && \mathbf{w}^\top \boldsymbol{\mu} \\ \text{sujeto a} &&& \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} \leq (\sigma_{\text{máx}}^{\text{periodo}})^2, \\ &&& \sum_{i=1}^K w_i = 1, \\ &&& 0 \leq w_i \leq w_{\text{máx}}, \quad i = 1, \dots, K. \end{aligned} \tag{5.10}$$

Es la única de las cuatro estrategias que impone el techo de riesgo $\sigma_{\text{máx}}$ de forma explícita: en las demás, el riesgo se gestiona a través de la propia función objetivo.

5.5.4. Estrategia de mínima varianza

La estrategia de mínima varianza (min_variance) busca, sobre los K activos seleccionados, la cartera de menor riesgo posible. No utiliza las predicciones de retorno en la ponderación (sí en la selección previa de los activos), lo que favorece de forma natural una asignación más diversificada y con activos poco correlacionados entre sí:

$$\begin{aligned} & \underset{\mathbf{w} \in \mathbb{R}^K}{\text{mín}} && \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} \\ \text{sujeto a} &&& \sum_{i=1}^K w_i = 1, \\ &&& 0 \leq w_i \leq w_{\text{máx}}, \quad i = 1, \dots, K. \end{aligned} \tag{5.11}$$

Al no imponerse la restricción de retorno ni el techo de riesgo (este último es innecesario, pues la propia función objetivo minimiza la varianza), la cartera resultante es la de mínimo riesgo alcanzable con el universo seleccionado.

5.5.5. Estrategia de media-varianza

La estrategia de media-varianza (mean_variance) es la formulación canónica de Markowitz, que combina en una única función objetivo el retorno esperado y el riesgo, ponderados por un coeficiente de aversión al riesgo $\lambda > 0$:

$$\begin{aligned} & \underset{\mathbf{w} \in \mathbb{R}^K}{\text{máx}} && \mathbf{w}^\top \boldsymbol{\mu} - \lambda \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} \\ \text{sujeto a} &&& \sum_{i=1}^K w_i = 1, \\ &&& 0 \leq w_i \leq w_{\text{máx}}, \quad i = 1, \dots, K. \end{aligned} \quad (5.12)$$

El coeficiente λ se recorre sobre el conjunto $\{1, 2, 3, 5, 10\}$: los valores bajos priorizan el retorno (aproximando la cartera al máximo retorno), mientras que los altos priorizan la reducción del riesgo (acercándola a la mínima varianza). Como $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ se expresan en la misma escala temporal, un mismo λ resulta comparable entre horizontes.

5.5.6. Estrategia de retorno objetivo

La estrategia de retorno objetivo (target_return) invierte el planteamiento del máximo retorno: en lugar de maximizar la rentabilidad bajo un techo de riesgo, minimiza el riesgo necesario para alcanzar una rentabilidad esperada mínima μ_{obj} . Este umbral se fija como rentabilidad anual y se convierte a la escala del periodo mediante $\mu_{\text{obj}}^{\text{periodo}} = \mu_{\text{obj}} \cdot h/252$ (escalado lineal en el tiempo, coherente con la escala de $\boldsymbol{\mu}$). La formulación es:

$$\begin{aligned} & \underset{\mathbf{w} \in \mathbb{R}^K}{\text{mín}} && \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} \\ \text{sujeto a} &&& \mathbf{w}^\top \boldsymbol{\mu} \geq \mu_{\text{obj}}^{\text{periodo}}, \\ &&& \sum_{i=1}^K w_i = 1, \\ &&& 0 \leq w_i \leq w_{\text{máx}}, \quad i = 1, \dots, K. \end{aligned} \quad (5.13)$$

Cuando la rentabilidad objetivo resulta infactible en un rebalanceo dado (ningún reparto de los K activos la alcanza dentro de las restricciones), el sistema recurre a la cartera de mínima varianza de la Ecuación 5.11.

5.5.7. Estimación de la matriz de covarianza

La matriz de covarianza Σ se estima en cada fecha de rebalanceo a partir de los log-retornos diarios de los K activos seleccionados, utilizando una ventana histórica de 252 sesiones (aproximadamente 1 año). La covarianza muestral diaria se anualiza multiplicándola por 252, de modo que quede en la misma escala que los retornos esperados μ y que el umbral de riesgo $\sigma_{\text{máx}}$. Finalmente se aplica una regularización mínima ($\Sigma \leftarrow \Sigma + 10^{-8} \cdot \mathbf{I}$), donde $\mathbf{I}$ es la matriz identidad, para garantizar la definición positiva de la matriz.

5.5.8. Rebalanceo periódico

La frecuencia de rebalanceo se sincroniza con el horizonte de predicción del modelo: la cartera se reconstruye cada vez que vence la predicción anterior. Así, un modelo con horizonte de 3 meses genera rebalanceos trimestrales, y un modelo con horizonte diario produce rebalanceos diarios. Esta coherencia garantiza que las predicciones utilizadas para la optimización son relevantes para el periodo de mantenimiento.

5.6. Módulo de evaluación y backtesting

El módulo de evaluación implementa un proceso completo de backtesting que simula la toma de decisiones de inversión sin acceso a datos futuros. Para cada fecha de rebalanceo, la cartera se construye utilizando exclusivamente información disponible hasta ese momento.

5.6.1. Los dos backtests: validación y test

El sistema puede ejecutar el backtesting de carteras sobre dos periodos temporales distintos, cada uno con un objetivo metodológico diferente. El periodo activo se controla mediante el parámetro `report_portfolio.evaluation_split` (por defecto `test`).

- **Backtest de validación** (2020–2021). Es un backtest exploratorio, empleado durante el desarrollo. Este mismo periodo se utiliza para seleccionar la arquitectura del modelo, el early stopping y los hiperparámetros, por lo que su resultado está sujeto a un sesgo de selección (optimista): se está midiendo el rendimiento sobre el mismo tramo que guió

las decisiones de diseño. No se usa como evidencia final de rendimiento.

- **Backtest de test** (2022 en adelante). Es la evaluación imparcial y out-of-sample. El modelo está congelado: no intervino ni en el ajuste de sus pesos (entrenamiento) ni en la selección de arquitectura o hiperparámetros (validación). Constituye la simulación honesta de cómo se habría comportado la estrategia ante datos completamente nuevos, e incluye además el mercado bajista de 2022, ausente del periodo de validación. Es el backtest que se reporta como evidencia de rendimiento.

Un backtest solo es metodológicamente válido cuando se realiza sobre datos out-of-sample con el modelo ya fijado; en caso contrario se mide el ajuste al propio periodo de desarrollo y no la capacidad de generalización. Por ello, la evaluación de referencia del sistema se realiza sobre el conjunto de test.

Las predicciones de validación las genera el propio proceso de entrenamiento con optimización de hiperparámetros (`pr-train-hpo`, o `pr-run-all`, que encadena la preparación de datasets y la búsqueda). Las de test las produce una herramienta de inferencia dedicada (`pr-predict-test`) que reutiliza los pesos ya entrenados, sin reentrenar: carga los checkpoints de las semillas del ensemble y ejecuta la inferencia sobre el tramo de test. De este modo se preserva la condición de modelo congelado.

5.6.2. Proceso de backtesting

El flujo de backtesting se ejecuta de forma independiente para cada horizonte de predicción y sigue estos pasos:

1. **Generación de fechas de rebalanceo:** se toman las fechas de señal del periodo de evaluación (test por defecto; véase la sección 5.6.1), espaciadas cada `holding_period_sessions` fechas.
2. **Selección de activos:** en cada fecha se ordenan los activos por retorno predicho y se seleccionan los top- K .
3. **Estimación de covarianza:** se calcula Σ con los retornos históricos anteriores a la fecha de rebalanceo.

4. **Optimización de pesos:** se resuelve el problema de Markowitz de la estrategia elegida (Ecuaciones 5.10–5.13), en su variante long-only y long-short.
5. **Evaluación del periodo:** se calcula el retorno real de la cartera hasta el siguiente rebalanceo como $r_p = \sum_{i=1}^K w_i \cdot r_i^{\text{real}}$.
6. **Acumulación:** se actualiza la curva de equity: $\text{equity}_t = \text{equity}_{t-1} \cdot (1 + r_p)$.

5.6.3. Métricas de rendimiento de carteras

Para cada configuración se calculan las siguientes métricas sobre la curva de equity:

- **Retorno total:** $R = \frac{\text{equity}_{\text{final}}}{\text{equity}_{\text{inicial}}} - 1$.
- **Retorno anualizado:** $(1 + R)^{252/N} - 1$, donde N es el número total de sesiones del periodo.
- **Volatilidad anualizada:** $\sigma_p \cdot \sqrt{252/h}$, donde σ_p es la desviación típica de los retornos por periodo y h las sesiones por periodo de holding.
- **Ratio de Sharpe:** $SR = R_{\text{anual}}/\sigma_{\text{anual}}$, asumiendo tasa libre de riesgo nula.
- **Ratio de Sortino:** variante del Sharpe que sustituye la volatilidad total por la desviación a la baja σ_{anual}^- , es decir, la volatilidad calculada únicamente sobre los retornos por periodo negativos: $\text{Sortino} = R_{\text{anual}}/\sigma_{\text{anual}}^-$. La desviación a la baja se obtiene como la desviación típica de los retornos por periodo $r_p < 0$ (umbral cero), anualizada mediante $\sigma_{\text{anual}}^- = \sigma_p^- \cdot \sqrt{252/h}$. Cuando no se registra ningún periodo con retorno negativo, el ratio queda indefinido (se reporta como N/A).
- **Máximo drawdown:** $MDD = \max_t \frac{\text{peak}_t - \text{equity}_t}{\text{peak}_t}$, donde $\text{peak}_t = \max_{s \leq t} \text{equity}_s$.

5.7. Módulo de explicabilidad de las decisiones

Para cada estrategia y fecha de rebalanceo, los módulos anteriores generan una cartera recomendada y su rentabilidad asociada. El módulo de explicabilidad permite comprender por qué el sistema propone esa composición, reconstruyendo la cadena desde la predicción de retornos

hasta la asignación final de pesos. Se ejecuta sobre los artefactos ya generados (modelos entrenados, predicciones y carteras del backtesting) sin intervenir en el entrenamiento ni modificar el proceso de decisión.

La explicación se adapta a la naturaleza de cada etapa. La selección de los K activos y la optimización de Markowitz son transparentes por construcción, ya que se basan, respectivamente, en una regla explícita de ordenación por retorno predicho y en una formulación matemática reconstruible a partir de los retornos esperados, el riesgo y las covarianzas. Por tanto, ambas se explican mediante trazabilidad directa. En cambio, la etapa predictiva utiliza una red recurrente de tipo caja negra y requiere una técnica post-hoc para estimar la contribución de las variables de entrada a la predicción.

En consecuencia, el módulo implementa tres análisis complementarios, cada uno adaptado a la etapa que explica.

El primero es la trazabilidad de la cadena de decisión. Para cada fecha de rebalanceo, reconstruye el recorrido de cada activo enlazando el retorno que predijo el modelo, la posición que ese valor le otorga en la ordenación, su inclusión o exclusión del conjunto de los K seleccionados y el peso que finalmente recibe. Se obtiene por cruce directo de los artefactos que el propio backtesting registra en cada rebalanceo (activos, retornos predichos y pesos), sin ningún modelo explicativo adicional.

El segundo es la descomposición de la optimización de Markowitz. Aprovechando que la asignación de pesos es transparente por construcción, descompone el peso de cada activo en su contribución al retorno esperado de la cartera ($w_i \mu_i$) y su contribución al riesgo, medida como aportación a la varianza total ($w_i (\Sigma \mathbf{w})_i$), de modo que la suma de las contribuciones al riesgo reproduce la varianza de la cartera. Para el término de riesgo se reestima la matriz de covarianza en la fecha del rebalanceo con la misma lógica que la optimización original, lo que garantiza la coherencia de la descomposición.

El tercero es la atribución de importancia de las variables de la red recurrente mediante Integrated Gradients, técnica post-hoc basada en gradientes que reparte la predicción entre las variables de entrada integrando el gradiente del modelo a lo largo de un camino desde una línea base hasta la entrada real. Como línea base se emplea el vector nulo en el espacio escalado que, por el escalado robusto, corresponde a la mediana de cada variable (una empresa

promedio). La técnica respeta la estructura temporal de la entrada, al producir una atribución para cada par (variable, sesión) de la ventana, lo que permite analizar tanto qué variables pesan más como qué sesiones de la ventana resultan más influyentes. La atribución se calcula sobre una única semilla del ensemble, por lo que ofrece una lectura orientativa de las variables relevantes.

El módulo se apoya en la librería `captum` para el cálculo de los gradientes integrados y opera en modo de solo lectura sobre los artefactos ya existentes (modelos entrenados, tablas de predicción y resultados de backtesting), depositando sus salidas en la capa de reporting (`06_reporting/explainability/`). Los resultados de estos análisis se presentan sobre decisiones concretas en el capítulo de evaluación (Capítulo 6), donde acompañan a los resultados de rendimiento de cada estrategia.

5.8. Entorno de ejecución

El sistema se implementa en Python 3.12 y la totalidad del desarrollo, el entrenamiento de los modelos y el backtesting se llevó a cabo en un único equipo personal, sin recurrir a infraestructura en la nube ni a servidores de cálculo externos, en línea con el requisito de ejecución local (RNF-03). Las características del equipo se resumen en la Tabla 5.6.

Cuadro 5.6. *Entorno de ejecución empleado en el desarrollo y la experimentación.*

Componente	Especificación
Procesador (CPU)	Intel Core i9-14900K (24 núcleos, 32 hilos)
Memoria (RAM)	64 GB
Tarjeta gráfica (GPU)	NVIDIA GeForce RTX 5080 (16 GB VRAM)
Sistema operativo	Windows 11 Pro (64 bits)
Python	3.12
PyTorch	2.7 (CUDA 12.8)

El entrenamiento de las redes recurrentes se ejecuta sobre la GPU mediante CUDA, lo que reduce de forma sustancial los tiempos de cada trial frente a una ejecución en CPU. Con todo, la capacidad de cómputo de un equipo personal impuso un límite práctico al alcance abordable: la optimización de hiperparámetros y el reentrenamiento multi-semilla de cada configuración, replicados para cada combinación de conjunto de datos, ventana temporal y horizonte de predicción, suponen un volumen de cómputo considerable. Este condicionante motivó varias de las decisiones de alcance del trabajo, como acotar el presupuesto de búsqueda de hiperpará-

metros y limitar el número de horizontes y el tamaño de la muestra analizada.

5.9. Ejecución de la herramienta

La herramienta se opera desde la línea de comandos. Los pipelines de Kedro se ejecutan mediante `uv run kedro run`, con la posibilidad de seleccionar un pipeline concreto o un subconjunto de nodos. Sobre esa base, el flujo completo de experimentación se reduce a cuatro comandos encadenados, declarados como puntos de entrada del paquete: `pr-run-all` prepara los conjuntos de modelado y ejecuta la optimización de hiperparámetros; `pr-predict-test` reentrena el ensemble de la configuración ganadora y genera las predicciones sobre el conjunto de test; `pr-backtest-all` construye y evalúa las carteras Markowitz sobre esas predicciones; y `pr-explainability` produce los artefactos de explicabilidad (trazabilidad, descomposición de la optimización e importancia de variables). Cada fase persiste sus resultados en disco, de modo que las etapas posteriores los consumen sin recalcular las anteriores.

El grafo de dependencias del pipeline puede visualizarse de forma interactiva mediante `uv run kedro viz`, lo que facilita la comprensión del flujo de datos entre las distintas etapas.

La reproducibilidad de los experimentos (RNF-01) se garantiza fijando de forma explícita las semillas aleatorias en todas las fuentes de aleatoriedad (Python, NumPy y PyTorch), gestionadas por el módulo `reproducibility.py`, y persistiendo los hiperparámetros de cada experimento junto a los checkpoints y las configuraciones serializadas, de modo que un experimento puede reconstruirse por completo a partir de los artefactos almacenados. La gestión de dependencias se realiza con `uv`, que genera un lockfile (`uv.lock`) con las versiones exactas de todas las dependencias transitivas (RNF-04): el entorno de ejecución se reconstruye de forma determinista mediante un único comando (`uv sync`).

6. Evaluación

Con la herramienta ya descrita, corresponde valorar su comportamiento sobre datos reales. La evaluación se estructura en dos niveles complementarios: en primer lugar, se describe la selección de los modelos recurrentes mediante optimización de hiperparámetros (con el RMSE de validación como criterio) y se evalúa la capacidad predictiva del ensemble resultante sobre el conjunto de test; en segundo lugar, se discute la aplicabilidad de estas predicciones para la construcción de carteras de inversión, también sobre el conjunto de test.

6.1. Configuración experimental

La evaluación se realiza sobre dos conjuntos de features que se comparan a lo largo del capítulo, market (retorno diario de mercado más la codificación one-hot de sector) y enriched (que añade las variables fundamentales), cuya construcción se detalla en la Sección 5.3.3.

Ambos conjuntos de datos se dividieron (5.3.5), obteniendo un subconjunto para el entrenamiento de los modelos y otro de validación, mientras que tanto las métricas de capacidad predictiva del modelo del ensemble final como la evaluación de carteras (backtesting) se reportan sobre el conjunto de test (de finales de 2021 a finales de 2024).

6.1.1. Métricas de evaluación del modelo predictivo

La calidad predictiva de los modelos se valora con un conjunto de métricas complementarias, que combinan la medida del error puntual de la predicción con la de su capacidad de ordenación. Estas métricas se reportan sobre el conjunto de test para el ensemble final de cada horizonte (Tabla 6.2), mientras que el RMSE de validación actúa como criterio de selección durante la optimización de hiperparámetros. Aunque las métricas se definen en este apartado, la justificación de por qué resultan relevantes para este problema se retoma al interpretar los resultados (Sección 6.3).

Para formalizar las definiciones, sea D el conjunto de fechas de señal (con $T = |D|$) y, en cada fecha $t \in D$, sea A_t el conjunto de activos disponibles ($n_t = |A_t|$). Para el activo i en la fecha t , $\hat{r}_{i,t}$ es el log-retorno predicho y $r_{i,t}$ el realizado. El conjunto de todas las observaciones (pares

activo-fecha) se denota $\mathcal{O}$, con $N = |\mathcal{O}|$.

- **Information Coefficient (IC):** en cada fecha de señal se calcula la correlación de rangos de Spearman entre el retorno predicho y el realizado a través de los activos disponibles ese día (correlación transversal entre empresas), y ese valor por fecha se promedia sobre todas las fechas:

$$IC = \frac{1}{T} \sum_{t \in D} \rho_{\text{Spearman}}((\hat{r}_{i,t})_{i \in A_t}, (r_{i,t})_{i \in A_t}),$$

donde $(\hat{r}_{i,t})_{i \in A_t}$ y $(r_{i,t})_{i \in A_t}$ representan las secuencias ordenadas de los retornos en el momento de la señal i . Se reporta también la fracción de IC positivo, $\frac{1}{T} \sum_{t \in D} \mathbf{1}[IC_t > 0]$, donde $\mathbf{1}[IC_t > 0]$ es la función indicatriz.

- **Long-Short Spread:** en cada fecha se ordenan los activos por retorno predicho, se toma el quintil superior Q_t^+ (20% con mayor predicción) y el inferior Q_t^- (20% con menor predicción), y se calcula la diferencia entre el retorno realmente obtenido por uno y otro grupo, promediada sobre las fechas:

$$\text{Spread} = \frac{1}{T} \sum_{t \in D} \left(\frac{1}{|Q_t^+|} \sum_{i \in Q_t^+} r_{i,t} - \frac{1}{|Q_t^-|} \sum_{i \in Q_t^-} r_{i,t} \right).$$

Se reporta también la fracción de spread positivo (proporción de fechas en que el quintil preferido supera al descartado), que mide la consistencia temporal de la selección con independencia de la magnitud del spread.

- **MAE / RMSE:** error absoluto medio y raíz del error cuadrático medio de los log-retornos predichos, calculados sobre todas las observaciones. Cuantifican la magnitud del error puntual de la predicción; el RMSE, al penalizar más los errores grandes, es más sensible a los fallos graves:

$$MAE = \frac{1}{N} \sum_{(i,t) \in \mathcal{O}} |\hat{r}_{i,t} - r_{i,t}|, \quad RMSE = \sqrt{\frac{1}{N} \sum_{(i,t) \in \mathcal{O}} (\hat{r}_{i,t} - r_{i,t})^2}.$$

- **Directional Accuracy:** fracción de predicciones que aciertan el signo del retorno (subida o bajada):

$$\text{DirAcc} = \frac{1}{N} \sum_{(i,t) \in \mathcal{O}} \mathbf{1}[(\hat{r}_{i,t} > 0) = (r_{i,t} > 0)].$$

- **Dispersion Ratio:** cociente entre la desviación típica de las predicciones y la de los retornos reales, que mide la dispersión de las predicciones relativa a la real:

$$\text{Disp} = \frac{\sigma(\hat{r}_t)}{\sigma(r_t)},$$

donde $\sigma(\hat{r}_t)$ y $\sigma(r_t)$ son las desviaciones típicas de las predicciones y de los retornos reales sobre el conjunto de observaciones.

Conviene precisar por qué se ha elegido este conjunto de métricas y qué papel juega cada una, pues no todas pesan lo mismo para el uso que se dará a las predicciones. La idea rectora es que, en la construcción de carteras, no interesa tanto acertar el valor exacto del retorno de cada activo como ordenarlos correctamente, ya que la cartera se forma seleccionando los mejores y ponderándolos. De ahí que las métricas de ordenación sean, en este contexto, más informativas que las de error puntual.

Conviene además distinguir dos papeles distintos: el RMSE de validación es el criterio de selección durante la optimización de hiperparámetros (la configuración ganadora es la de menor RMSE), mientras que el IC es la métrica principal para valorar la utilidad de las predicciones ya seleccionadas de cara a la cartera, precisamente porque mide la capacidad de ordenar los activos por retorno esperado, que es lo que aprovecha el módulo de construcción de carteras al quedarse con los K mejores. El long-short spread complementa esta lectura al comprobar si los activos mejor valorados rinden efectivamente más que los peor valorados, y la directional accuracy y el dispersion ratio matizan, respectivamente, el acierto en el signo y el grado en que el modelo discrimina entre activos en lugar de predecir un valor casi constante.

6.2. Análisis de arquitecturas

La selección del modelo no se realiza fijando a priori una arquitectura, sino mediante una optimización de hiperparámetros (HPO) con Optuna. Para cada horizonte de predicción se ejecuta un estudio independiente que busca, mediante un muestreador bayesiano (Tree-structured Parzen Estimator, TPE) con pruning por mediana, la configuración que minimiza el RMSE sobre el conjunto de validación.

El espacio de búsqueda abarca tanto la arquitectura como los hiperparámetros de entrena-

miento:

- **Tipo de red:** RNN, GRU o LSTM.
- **Tamaño de capa oculta:** 32, 64, 128 o 256 unidades.
- **Número de capas:** entre 1 y 10.
- **Bidireccionalidad:** sí o no.
- **Regularización:** dropout recurrente y de la cabeza, y weight decay.
- **Cabeza de regresión:** tamaño y función de activación.
- **Tasa de aprendizaje:** en escala logarítmica.

El conjunto de features (market o enriched) no se incluye como una dimensión del espacio de búsqueda, sino que se optimiza con un estudio independiente por conjunto: cada uno recibe el mismo presupuesto de trials y produce su propio modelo ganador, de modo que ambos son directamente comparables. Cada estudio ejecuta 10 trials con una semilla por trial; el pruning aborta anticipadamente los trials poco prometedores según el RMSE de validación reportado por época. La Tabla 6.1 recoge, para cada horizonte, la configuración ganadora (la del conjunto con menor RMSE de validación) y su RMSE de validación (escala del target estandarizado).

Cuadro 6.1. Configuración ganadora por horizonte tras la optimización de hiperparámetros.

Horizonte	Sesiones (h)	Red	Oculto	Capas	Bidir.	Dataset	RMSE val.	Compl./Prun.	Parám.
1 día	1	RNN	32	7	No	enriched	1.338	8/2	15 201
1 semana	5	GRU	256	8	No	market	1.340	10/0	2 979 393
2 semanas	10	RNN	256	5	No	market	1.425	9/1	604 225
1 mes	21	LSTM	128	2	No	enriched	1.466	8/2	214 305
2 meses	42	RNN	256	5	No	enriched	1.433	10/0	607 809
3 meses	63	LSTM	32	1	No	enriched	1.217	9/1	8 289
6 meses	126	GRU	256	8	No	market	1.134	10/0	2 979 393

De estos resultados se extrae que ningún tipo de red domina de forma absoluta: la RNN simple gana en 3 de los 7 horizontes (2 semanas, 2 meses y, junto a enriched, 1 día), la GRU en los dos que emplean el conjunto market de mayor tamaño (1 semana y 6 meses) y la LSTM en dos horizontes con conjunto enriched (1 mes y 3 meses); en ningún caso la configuración ganadora es bidireccional, lo que sugiere que la información futura de la ventana no aporta a esta tarea.

Tampoco se aprecia un patrón entre el horizonte de predicción y el conjunto de datos: el enriched gana en cuatro horizontes (1 día, 1 mes, 2 meses y 3 meses) y el market en tres (1 semana, 2 semanas y 6 meses), de modo que la información fundamental resulta competitiva en varios horizontes, especialmente los intermedios.

Por su parte, el RMSE de validación tiende a decrecer con el horizonte (de 1.338 a 1 día hasta 1.134 a 6 meses, con un repunte a 1 mes), lo que apunta a que a mayor plazo se exista una relación señal/ruido algo más favorable que en los datos de retorno diario.

Finalmente, el pruning descarta parte del espacio de búsqueda, pues en varios estudios se podan 1 o 2 de los 10 trials, lo que confirma que algunas configuraciones se revelan claramente inferiores y se abortan pronto.

Una vez seleccionada la configuración ganadora de cada horizonte, se reentrena con 5 semillas aleatorias distintas ($\{11, 23, 42, 71, 101\}$) sobre el conjunto de entrenamiento y validación, y las predicciones finales sobre test se obtienen como el promedio (ensemble) de las 5 semillas. Este promediado reduce la varianza asociada a la inicialización aleatoria y al orden del entrenamiento.

La Tabla 6.2 presenta las métricas del ensemble de 5 semillas evaluadas sobre el conjunto de test, para cada horizonte.

Cuadro 6.2. Métricas del ensemble de 5 semillas con la configuración ganadora de cada horizonte sobre el conjunto de test.

Horizonte	Sesiones (h)	MAE	RMSE	DirAcc (%)	IC medio	IC+ (%)	Spread	Spread+ (%)	Disp.
1 día	1	0.01673	0.02497	50.9	+0.00223	49.7	+0.00038	51.9	0.0174
1 semana	5	0.03674	0.05430	52.4	-0.00429	48.2	-0.00036	48.1	0.0490
2 semanas	10	0.05176	0.07525	53.2	-0.00165	48.4	-0.00015	48.5	0.0230
1 mes	21	0.07506	0.10692	54.2	+0.01004	47.7	+0.00480	50.5	0.0376
2 meses	42	0.10498	0.14772	56.0	+0.03049	58.0	+0.01312	56.2	0.0662
3 meses	63	0.12447	0.17503	57.5	+0.03393	54.3	+0.01635	59.2	0.0427
6 meses	126	0.17227	0.23952	60.4	-0.01515	42.5	-0.01322	40.3	0.1448

A partir de las métricas MAE y RMSE, se observa que los errores de predicción del modelo tienden a incrementarse a medida que aumenta el horizonte temporal. Este comportamiento es coherente con lo esperado, ya que, en horizontes más amplios, los log-retornos acumulan de forma aditiva los errores asociados a las predicciones diarias, lo que da lugar a una mayor incertidumbre en las estimaciones a largo plazo.

La directional accuracy (DirAcc) supera de forma modesta pero creciente el 50% a medida que

aumenta el horizonte (del 50.9% a 1 día al 60.4% a 6 meses). Esto apunta a que el modelo tiende a predecir de forma más favorable el signo de los retornos cuanto mayor es el horizonte de predicción.

Sin embargo, las métricas de IC medio del ensemble sobre test confirman la limitada capacidad de ordenación de los modelos en horizontes cortos, aunque muestran una señal algo más favorable a plazos intermedios. Como se observa en la tabla, el IC medio se mantiene próximo a cero en los horizontes diario y semanal (entre -0.004 y $+0.002$), mientras que pasa a ser positivo a 2 y 3 meses ($+0.030$ y $+0.034$, con fracciones de días de IC positivo del 58% y 54% respectivamente), para volver a descender a 6 meses (-0.015), si bien este último resultado se obtiene sobre un número muy reducido de fechas. En conjunto, estos resultados sugieren que el modelo, por sí solo, no es capaz de generar predicciones que permitan establecer ordenaciones del universo de activos con un grado de fiabilidad suficiente. No obstante, esto no implica necesariamente que las K empresas identificadas por el modelo como más prometedoras no lo sean, sino que no existe evidencia estadística suficiente para afirmar que dicha selección sea consistentemente fiable.

Por otro lado, la fracción de fechas con spread positivo confirma la lectura del IC: se mantiene en torno al 48%–52% (indistinguible del azar) a horizonte corto, sube a su máximo a 2 y 3 meses (56.2% y 59.2%, es decir, en casi seis de cada diez rebalanceos los activos preferidos batían a los descartados) y cae al 40.3% a 6 meses, donde el escaso número de fechas resta fiabilidad. El dispersion ratio es muy bajo a horizonte diario (0.017, predicciones casi constantes en torno a la media) y crece de forma irregular con el horizonte (hasta 0.145 a 6 meses), recuperando parte de la variabilidad real a medio plazo. En conjunto, la señal predecible es débil pero no nula, y resulta algo más favorable a los horizontes intermedios, lo que es coherente con el mejor rendimiento de las carteras enriched en esa franja.

6.2.1. Curvas de aprendizaje y parada temprana


El reentrenamiento multi-semilla de la configuración ganadora de cada horizonte emplea la parada temprana descrita en el diseño (Sección 5.4.4): el entrenamiento se detiene cuando la pérdida de validación deja de mejorar durante 8 épocas y se restaura el checkpoint de la mejor época.

Para cada horizonte se obtiene una figura con dos paneles apilados: arriba, la pérdida de validación por época (una curva por semilla, con la época del mejor checkpoint marcada sobre cada curva); abajo, la de entrenamiento. Ambas curvas se muestran en paneles separados de forma deliberada, porque miden el error sobre conjuntos distintos (entrenamiento y validación) y en escalas que no son directamente comparables: superponerlas induciría a leer su diferencia de nivel como un sobreajuste que, en realidad, refleja sobre todo la distinta dificultad de ambos periodos.

Se observa que la gráfica de validación se estabiliza muy pronto, en pocas épocas deja de mejorar de forma apreciable, y a partir de ahí tiende a estancarse o empeorar ligeramente, momento en que la parada temprana detiene el entrenamiento y conserva el mejor checkpoint.

A título ilustrativo, las Figuras 6.1 y 6.2 muestran las curvas de aprendizaje del horizonte semanal para los conjuntos market y enriched, respectivamente. Las curvas del resto de horizontes, que presentan un comportamiento análogo, se recogen en el Anexo 9.


Figura 6.1. *Curvas de aprendizaje por semilla (conjunto market, horizonte 1 semana).*



6.3. Discusión de resultados

En base a la lectura conjunta de las métricas del ensemble de 5 semillas sobre test (Tabla 6.2), se observa que los modelos recurrentes seleccionados presentan una capacidad predictiva muy

Figura 6.2. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 semana).*



limitada para los retornos de las acciones, especialmente a horizontes cortos, si bien la escasa señal aprovechable se vuelve algo más apreciable a plazos intermedios.

La evidencia más directa la aporta el Information Coefficient, que mide la capacidad del modelo para ordenar el universo de activos. Su valor medio es prácticamente nulo a 1 día y 1 semana (entre -0.004 y $+0.002$) y solo alcanza el rango en el que podría considerarse mínimamente útil a plazos intermedios (2 y 3 meses, con $+0.030$ y $+0.034$), en horizontes con pocas fechas de rebalanceo. Sobre esta base no se identifica evidencia de que el modelo tenga capacidad de ordenar el universo de activos con la fiabilidad suficiente para decidir de forma consistente. Esta lectura es coherente con el resto de métricas: el dispersion ratio es de apenas el 1,7% a 1 día, lo que indica que el modelo aprende esencialmente a predecir la media incondicional (predicciones casi constantes), y crece de forma irregular con el horizonte (hasta 0.145 a 6 meses), recuperando parte de la variabilidad real a medio plazo. La directional accuracy, que sube del 50.9% a 1 día al 60.4% a 6 meses, exhibe un patrón creciente pero modesto. En conjunto, tanto el IC como la directional accuracy son más favorables a horizontes intermedios que a horizonte diario, lo que sugiere que la escasa señal predecible es más persistente a medio plazo que en el retorno diario.

Si observamos el long-short spread, que compara el retorno realmente obtenido por el quintil

de activos que el modelo prefiere frente al que descarta, a horizonte diario vemos valores de apenas 0.0004 (0.04% entre ambos quintiles), prácticamente indistinguible de cero, de modo que una estrategia long-short basada en esta ordenación no generaría un exceso de retorno apreciable. A plazos intermedios, en cambio, el spread se vuelve claramente positivo (hasta +0.016 a 3 meses), coherente con el IC positivo observado en esa franja: la ordenación del modelo separa mejor ganadores de perdedores a medio plazo que a horizonte diario. Sin embargo, aunque favorable, la métrica sigue siendo baja.

La dificultad para predecir los retornos, especialmente a horizonte diario, puede atribuirse a varios factores que se refuerzan entre sí. En primer lugar, la hipótesis de mercados eficientes: los precios de las acciones líquidas incorporan la información disponible con rapidez, lo que deja poco margen para predicciones basadas en patrones históricos. A ello se suma una relación señal/ruido muy desfavorable, pues los retornos diarios están dominados por ruido estocástico y la señal predecible, si existe, es varios órdenes de magnitud inferior a la varianza de ese ruido. La no estacionariedad de las series agrava el problema, ya que las relaciones estadísticas entre las features y los retornos cambian a lo largo del tiempo y limitan la generalización de un modelo entrenado en un periodo a otro distinto. Por último, el propio horizonte de predicción influye de forma decisiva: un horizonte de una sola sesión es especialmente difícil de anticipar, mientras que los plazos más largos pueden capturar señales algo más persistentes, hipótesis que motiva precisamente que el sistema implemente siete horizontes distintos (de 1 día a 6 meses) y que se observe cierta mejora de las métricas observadas a plazos intermedios.

6.4. Evaluación de carteras Markowitz

Además de evaluar la capacidad predictiva del modelo de forma aislada, resulta necesario determinar en qué medida dicha capacidad se traduce en utilidad práctica dentro del objetivo final del sistema: la generación de recomendaciones para la construcción de carteras de inversión. Con este propósito, el módulo de *backtesting* permite evaluar de forma conjunta las distintas etapas que intervienen en el proceso de decisión, desde la selección de activos hasta la asignación de pesos mediante optimización de Markowitz.

A partir de este planteamiento, la evaluación se articula en torno a dos cuestiones principales. En primer lugar, determinar si las recomendaciones generadas por la herramienta resultan de

utilidad desde el punto de vista de la inversión y, en segundo lugar, en caso de que así sea, determinar la consistencia de dicha utilidad y cuáles son las condiciones que se deben reunir para mantener dicha consistencia.

Con este marco, la sección describe en primer lugar la configuración experimental del *back-testing* y los comparadores empleados. A continuación, se analiza el comportamiento de las carteras de cada conjunto de datos frente al mercado y, por último, se discuten los resultados retomando las dos cuestiones anteriores, tanto la generación de valor frente al mercado como el origen y los límites de ese valor.

6.4.1. Configuración del backtesting de carteras

El backtesting de referencia se ejecuta sobre el conjunto de test (desde finales de 2021 hasta finales de 2024) para cada horizonte de predicción. Esta es la evaluación out-of-sample, es decir, que los datos que se manejan en este periodo no participan de modificar el modelo ya entrenado. Es, por tanto, la simulación honesta de cómo se habría comportado la estrategia ante datos que el modelo nunca vio, e incluye además el mercado bajista de 2022, ausente del periodo de validación.

Cuadro 6.3. *Parámetros de configuración del backtesting de carteras.*

Parámetro	Valor configurado
Selección top- K	5, 10, 15 y 20 activos
Volatilidad máxima ($\sigma_{\text{máx}}$)	20% anual
Límite de concentración ($w_{\text{máx}}$)	30% por activo
Apalancamiento máximo <i>long-short</i> (L)	1,5 (exposición bruta)
Barrido de aversión al riesgo (λ)	{1, 2, 3, 5, 10} (media-varianza)
Retorno objetivo (r_{obj})	15% anual (estrategia de retorno objetivo)
Ventana de covarianza	252 sesiones
Frecuencia de rebalanceo	Coincide con el horizonte de predicción

Se cuenta con un total de cuatro estrategias de optimización (máxima rentabilidad, mínima varianza, media-varianza y retorno objetivo)¹, que pueden ser implementadas en dos variantes

¹ Para más información sobre las estrategias véase la sección 5.5

(long-only y long-short) y dos fuentes de datos (market y enriched).

Cada periodo se valora comprando en la fecha de rebalanceo y vendiendo al finalizar el periodo de holding (buy-and-hold intra-periodo). Esto se aplica por igual a todas las estrategias para que la comparación sea homogénea. En la tabla 6.3 se presenta la configuración empleada.

Para juzgar la bondad de las carteras propuestas por el modelo no basta con observar sus métricas de forma aislada: hace falta contrastarlas con estrategias de referencia que sirvan de punto de comparación:

- **S&P 500 en buy & hold:** se mantiene el índice de mercado S&P 500 durante todo el periodo, encadenando el retorno obtenido entre fechas de rebalanceo. Representa la referencia mínima que cualquier estrategia activa debe superar para justificar el uso la herramienta: si el modelo no bate a comprar y mantener el índice, no aporta valor frente a la gestión pasiva.
- **Cartera S&P 500 + activo seguro:** cartera de dos activos optimizada por Markowitz que reparte peso entre el índice (activo de riesgo) y un activo seguro sintético que crece a una inflación anual fija del 3,29% (media histórica del IPC de Estados Unidos en 1914–2026 según la U.S. Bureau of Labor Statistics). El activo seguro actúa como refugio de baja volatilidad hacia el que la optimización desplaza peso cuando el índice no ofrece una prima de riesgo atractiva, por lo que constituye una referencia de mercado con gestión del riesgo.
- **Cartera equiponderada:** reparte el capital a partes iguales ($w_i = 1/K$) entre los mismos K activos que el modelo selecciona en cada rebalanceo, sin optimizar los pesos. Parte de la propia selección del modelo y permite aislar el origen del valor: si la cartera optimizada por Markowitz supera a la equiponderada de esos mismos activos, el mérito procede de la ponderación de los pesos. En caso contrario, el valor (de haberlo) reside únicamente en la selección top- K .

Aunque es posible alternar el conjunto de datos o la estrategia de optimización en cada rebalanceo, a lo largo de la evaluación cada configuración mantiene fijos el conjunto (market o enriched) y la estrategia durante todo el periodo, para poder comparar.

Conviene aclarar cómo se combinan la estrategia de optimización de la cartera y la variante, pues son dos ejes independientes. La estrategia define la función objetivo del problema de Markowitz (máxima rentabilidad, mínima varianza, media-varianza con su barrido de λ , o retorno objetivo), mientras que la variante define el espacio de pesos admisibles: long-only restringe todos los pesos a valores no negativos ($w_i \geq 0$), mientras que long-short permite posiciones cortas ($w_i < 0$) sujetas a un apalancamiento bruto máximo $L = 1,5$.

La cartera equiponderada es la única excepción: al no optimizar pesos sino repartir el capital a partes iguales ($w_i = 1/K$), es intrínsecamente long-only y no admite variante long-short.

Conviene tener presente, por último, cuántas oportunidades de decisión ofrece cada horizonte, pues de ello depende la solidez de las conclusiones. El número de rebalanceos disponibles sobre el periodo de test decrece al alargar el periodo de holding, tal como recoge la Tabla 6.4.

Cuadro 6.4. *Número de rebalanceos disponibles por horizonte sobre el conjunto de test (finales de 2021 a finales de 2024).*

Horizonte	Sesiones de holding	Rebalanceos
1 día	1	750
1 semana	5	149
2 semanas	10	74
1 mes	21	34
2 meses	42	16
3 meses	63	10
6 meses	126	4

Esta reducción no es exactamente proporcional al horizonte por un efecto de borde: solo se contabilizan los periodos de holding que se cierran íntegramente dentro del conjunto de test, de modo que los tramos finales cuyo vencimiento caería más allá del último dato disponible (por ejemplo, una compra a 6 meses en la segunda mitad de 2024, que vencería en 2025) quedan excluidos. Por ello, a horizontes largos el número efectivo de rebalanceos es aún menor de lo que sugeriría el reparto teórico del periodo (a 6 meses, 4 rebalanceos frente a los seis que cabrían nominalmente en tres años), por lo que los resultados de los horizontes más grandes serán menos significativos.


Bajo esta óptica, el S&P 500 es la referencia permanente contra la que se mide todo, y no una configuración más del estudio. Como el volumen de configuraciones evaluadas (más de mil, contando los siete horizontes y los dos conjuntos), los resultados se organizan mediante un análisis agregados para responder a las preguntas planteadas al inicio de la sección..

6.4.2. Resultados del backtesting

Todas las figuras de este apartado se construyen con el mismo procedimiento a partir de las métricas de backtesting de las configuraciones del modelo (las 64 por horizonte y conjunto), tomando como referencias de mercado el S&P 500 en buy & hold y la cartera S&P 500 + activo seguro.

La figura 6.3 muestra, para el conjunto de market, el diferencial de ratio de Sharpe de cada configuración respecto al S&P 500 durante el periodo de test, en una rejilla configuración $\times$ horizonte. Para que la figura sea legible se muestran las 25 configuraciones con mayor diferencial medio a lo largo de los horizontes, ordenadas de arriba (mejores en promedio) a abajo.

Figura 6.3. Diferencial de ratio de Sharpe respecto al S&P 500 por configuración y horizonte sobre el conjunto market.




En verde las configuraciones que baten al índice. En rojo las que quedan por debajo. Fuente: Elaboración propia.

En 6.3 podemos observar un mejor ratio para los horizontes de un día, una semana y seis meses, aunque este último debido a la reducida cantidad de rebalanceos que se efectúan proporciona métricas menos fiables. En cambio, el resto de horizontes ubicados en la franja intermedia presentan ratios de Sharpe peores que el SP&500.

Si analizamos este gráfico de cajas 6.4 confirmamos la tendencia identificada en el mapa de calor anterior. En general, las configuraciones para horizontes entre dos semanas y tres meses quedan por debajo en más de la mitad de sus configuraciones del ratio de Sharpe del S&P 500 e incluso, entre estos casos, en su mayoría quedaron por debajo de la cartera que combina el índice con el activo seguro. Esto significa que la rentabilidad ajustada al riesgo solo es mejorada, en general, por las configuraciones en horizontes de hasta una semana y, adicionalmente, seis meses. Notamos además que el ratio de Sharpe es negativo para buena parte de las configuraciones en el horizonte temporal de dos meses.

Por otro lado, se observa que existen diferencias significativas en el comportamiento de las distribuciones para distintos horizontes temporales, lo que indica que este factor es influyente para la bondad de las carteras proporcionadas por la herramienta.


Figura 6.4. Distribución del ratio de Sharpe por horizonte (todas las configuraciones) sobre el conjunto market



Si analizamos el gráfico de dispersión 6.5, podemos apreciar un mayor peso bajo la línea definida por el ratio de Sharpe del S&P 500. En consonancia con lo observado en el gráfico de cajas, la mayor parte de las configuraciones por encima esta misma línea presentan colores más cla-

ros, con algunas excepciones en los tonos más oscuros, y, en consonancia con los tendencias identificadas en el mapa de calor, encontramos que estas mismas configuraciones están ubicadas en la banda que va entre el $[0, 0.4]$ del ratio de Sharpe, por debajo de la línea de Sharpe 1 mayoritariamente, revelando que estas configuraciones presentaron un peor rendimiento en cuanto a sus retornos ajustados al riesgo.


Figura 6.5. *Dispersión retorno-riesgo de todas las configuraciones, conjunto market, con el S&P 500 como referencia.*



Por otro lado, la Figura 6.6 revela que, en aquellos horizontes en los que la rentabilidad ajustada al riesgo del conjunto *market* ya quedaba por debajo del índice, la penalización se agrava al considerar únicamente el riesgo de caída. El ratio de Sortino, que sustituye la volatilidad total por la desviación calculada solo sobre los periodos de retorno negativo, se sitúa en esos horizontes por debajo del de las referencias de mercado (el S&P 500 y la cartera con activo seguro): las configuraciones no solo rinden menos, sino que lo hacen sufriendo caídas proporcionalmente mayores que las del mercado. Este deterioro es coherente con la fracción de configuraciones que baten al índice, que a horizontes intermedios se desploma en *market* (apenas un 2%–25% a partir de dos semanas, frente al 100% de los horizontes diario y semanal). El caso más acusa-

do es el horizonte de dos meses, donde gran parte de las configuraciones presentan un ratio de Sortino negativo, lo que refleja que su retorno medio fue negativo y que las caídas dominaron el periodo.

Figura 6.6. Distribución del ratio de Sortino por horizonte (todas las configuraciones), conjunto market, con las referencias de mercado superpuestas.




El eje vertical se recorta en 4 para que los diagramas de caja sean legibles. Fuente: Elaboración propia.

Para entender mejor el comportamiento del riesgo respecto a los retornos, nos apoyamos en la Figura 6.7, donde se presenta el gráfico de dispersión del retorno frente al máximo drawdown de cada configuración, empleando esta última magnitud como medida de riesgo por resultar más tangible para el inversor que la volatilidad. Frente a las líneas de referencia del S&P 500 (su retorno y su drawdown), se aprecia una parte sustancial de configuraciones situadas por debajo y a la derecha del índice, es decir, que con una rentabilidad inferior presentaron además caídas desde máximos más pronunciadas. En términos agregados, el máximo drawdown medio de las carteras de *market* es del orden del 20%–35% según el horizonte, por encima del entorno del 15% del índice, lo que confirma que el mayor riesgo asumido no siempre se ve compensado por un retorno superior.

Para un usuario con especial aversión al riesgo este comportamiento es especialmente preocupante. En la tabla 6.5 se recogen la cantidad de configuraciones encontradas en este cuadrante. Un usuario que opte por la estrategia de media-varianza para poder ajustar su perfil de riesgo puede encontrar 56 configuraciones para cada uno de los valores de λ que tiene disponible para

ello. Revisando qué configuraciones presentan el peor caso para cada valor de λ encontramos los resultados de la tabla, donde podemos comprobar que casi la mitad de las configuraciones están en el peor caso para el conjunto de datos de market.

Figura 6.7. *Dispersión retorno-drawdown de todas las configuraciones, conjunto market.*



Si observamos ahora el reparto de los puntos entre los cuadrantes que definen las líneas del índice, no se aprecia una tendencia clara: existe una cantidad similar de configuraciones que mejoran el retorno del índice (por encima de su línea horizontal) y de las que no lo hacen, sin un patrón dominante. Por otra parte, solo una minoría de configuraciones se ubica en el cuadrante superior-izquierdo respecto del índice, que corresponde al caso ideal: batir al S&P 500 en rentabilidad y, a la vez, con un máximo drawdown durante el periodo de tenencia menor que el suyo. La mayoría de las configuraciones que superan al índice en retorno lo hacen, por tanto, asumiendo caídas mayores que las del mercado, de modo que su ventaja en rentabilidad se paga con un riesgo de caída superior.

Si abordamos este mismo análisis para el conjunto enriched, el panorama cambia radicalmente. Las veinticinco configuraciones con mejor promedio de Sharpe entre horizontes (Figura 6.8)

Cuadro 6.5. *Configuraciones de media-varianza del conjunto market en el peor cuadrante frente al S&P 500.*

λ	N.º de configuraciones	%
1	22	39,3%
2	22	39,3%
3	22	39,3%
5	22	39,3%
10	23	41,1%
Total	111 / 280	39,6%

presentan en su totalidad una mejora del ratio respecto al S&P 500. Esa mejora se acentúa hacia los horizontes más largos: en el de seis meses, más de la mitad de esas configuraciones muestran el diferencial más pronunciado.

En general, la ventaja de Sharpe sobre el índice tiende a crecer conforme se alarga el horizonte temporal, lo que apunta a que los horizontes mayores benefician a la rentabilidad ajustada al riesgo cuando se dispone de información fundamental. No obstante, conviene recordar que los horizontes de tres y seis meses se apoyan en muy pocos rebalanceos (diez y cuatro respectivamente), por lo que su lectura es más orientativa que concluyente.


Este contraste con el conjunto market, que a horizontes intermedios apenas batía al índice (solo entre un 2% y un 25% de sus configuraciones lo superaban), apoya el indicio de que es la información fundamental la que dota de consistencia a las recomendaciones a medio plazo.

El diagrama de caja (Figura 6.9) confirma, para la mayoría de las configuraciones, las tendencias identificadas en el mapa de calor de la Figura 6.8. La principal excepción es el horizonte de una semana, en el que casi la mitad de las configuraciones quedan por debajo del ratio de Sharpe del índice; es, de hecho, el único horizonte en el que enriched no supera con holgura al mercado, coherente con que a esa frecuencia era el conjunto market el que dominaba. Aun así, en todos los horizontes las carteras superan a la cartera compuesta por el índice y el activo seguro.

Se observa además que la distribución de las configuraciones cambia de forma apreciable, tanto en dispersión como en nivel de rentabilidad, al variar el horizonte, lo que apunta a que este es un factor influyente en el rendimiento de las carteras.

La Figura 6.10 muestra la distribución del ratio de Sortino para el conjunto enriched. En ella se observa que, de forma mayoritaria, los valores de esta métrica superan a los del índice de

Figura 6.8. Diferencial de ratio de Sharpe respecto al S&P 500 por configuración y horizonte sobre el conjunto enriched.



En verde las configuraciones que batien al índice. En rojo aquellas que quedan por debajo. Fuente: Elaboración propia.

Figura 6.9. Distribución del ratio de Sharpe por horizonte (todas las configuraciones) para el conjunto enriched.





Figura 6.10. Distribución del ratio de Sortino por horizonte (todas las configuraciones) para el conjunto enriched



referencia e incluso a los de la cartera que lo combina con el activo seguro. Dado que el Sortino penaliza únicamente la volatilidad de las caídas, este resultado indica que las carteras de enriched no solo rinden más que el mercado, sino que además contienen mejor el riesgo a la baja.

Cabe resaltar que en esta gráfica se recortó la escala en el eje Y hasta 10 porque un pequeño grupo de configuraciones alcanza valores muy superiores. Estas configuraciones atípicas, emplean la variante long-short y se concentran en los horizontes de 2 y 3 meses. En la tabla 6.6 se presentan sus valores.

Cuadro 6.6. Configuraciones con ratio de Sortino superior a 10 (conjunto enriched, periodo de test). Se muestra su ratio de Sharpe como contraste.

Horizonte	Configuración	Sharpe	Sortino
3 meses	Media-varianza ($\lambda = 5$) long-short, top-20	1,21	38,5
3 meses	Máx. rentabilidad long-short, top-15	1,55	29,5
2 meses	Máx. rentabilidad long-short, top-20	2,02	18,6
3 meses	Media-varianza ($\lambda = 10$) long-short, top-20	1,13	16,0


Estos valores no reflejan una calidad excepcional, dada su naturaleza atípica. El ratio de Sortino divide el retorno por la desviación a la baja, es decir, por la volatilidad calculada solo con los periodos de retorno negativo. Sobre los pocos rebalanceos disponibles a estos horizontes (16 a 2 meses y 10 a 3 meses), estas carteras apenas registran periodos negativos y, cuando lo hacen, son de magnitud ínfima, de modo que el denominador se aproxima a cero y el cociente se dispara.

La prueba de que se trata de un espejismo estadístico es que el ratio de Sharpe de esas mismas configuraciones se mantiene en valores razonables (entre 1,1 y 2,0), pues su denominador es la volatilidad total y no solo la de las caídas. Por ello estos valores se descartan como evidencia de rendimiento, en coherencia con la cautela general hacia los horizontes de 3 y 6 meses.

En la Figura 6.11 se aprecia que el comportamiento del rendimiento de las carteras respecto a la volatilidad difiere sustancialmente del encontrado en el conjunto market (Figura 6.5). En consonancia con lo observado en los diagramas de caja del ratio de Sharpe, la nube de configuraciones se sitúa mayoritariamente por encima de la recta del Sharpe del índice. Un volumen importante de ellas cae entre las isolíneas de Sharpe 0,5 y 1, lo que corresponde a carteras cuya rentabilidad ajustada al riesgo es solo moderada; no obstante, una fracción no despreciable supera la isolínea de Sharpe 1, ofreciendo alternativas con un rendimiento ajustado al riesgo atractivo.

Cabe añadir que existen configuraciones que quedan por debajo de las métricas del S&P 500. Entre ellas se observan tonos tanto claros como oscuros, por lo que no se aprecia un patrón claro que asocie ese peor comportamiento a un horizonte concreto.


Figura 6.11. *Dispersión retorno-riesgo de todas las configuraciones, conjunto enriched.*



La Figura 6.12 permite comprobar cómo se comporta el máximo drawdown de las carteras del conjunto enriched respecto a su rentabilidad. El contraste con el conjunto market es notable:

en enriched no se observa ninguna configuración en el cuadrante inferior-derecho respecto del índice (0 de 280), es decir, ninguna cartera queda simultáneamente por debajo del S&P 500 en rentabilidad y por encima en máximo drawdown. Esto refuerza que la información extraída de los estados financieros aporta valor: con ella, ningún valor de λ produce carteras dominadas por el mercado en rentabilidad y caída a la vez.

Figura 6.12. *Dispersión retorno-drawdown de todas las configuraciones para el conjunto enriched.*



Entre las configuraciones con rentabilidad por debajo del índice pero con un máximo drawdown también inferior al suyo (cuadrante inferior-izquierdo) se observan pocas y de tonos mayoritariamente oscuros, es decir, correspondientes a horizontes largos, donde las caídas resultan más controladas; conviene recordar, no obstante, que a esos horizontes el número de rebalances es reducido y la fiabilidad de las métricas es limitada.


Lo más destacable es que, a diferencia del conjunto market, en enriched se aprecia un volumen apreciable de configuraciones en el cuadrante superior-izquierdo respecto del índice, que representa el escenario ideal: mejor rentabilidad que el mercado y, a la vez, menores caídas máximas durante el periodo de tenencia. En ese cuadrante predominan los horizontes cortos e intermedios.

Para completar la lectura del comportamiento de las carteras a lo largo del tiempo, las Figuras

6.13 y 6.14 muestran, a título ilustrativo, la evolución de las curvas de equity en todos los horizontes y en escala logarítmica. El criterio de elegibilidad de las series representadas fue fijar la configuración de referencia en top-10 para cada conjunto de datos. Para ese tamaño, se tomó las dos variantes de la estrategia de máxima rentabilidad (long-only y long-short), la cartera equiponderada como referencia, ya que la que la ponderación de pesos no participa y el S&P 500 en buy & hold como referencia de mercado.

De su observación se advierte que el crecimiento de las carteras estuvo más estancado en los tramos del periodo de test que pueden asociarse a las fases de mayor incertidumbre del mercado (esto es, la corrección de 2022) y que, en cambio, se acelera en la fase alcista posterior, lo que sugiere que el contexto de mercado favorable pudo contribuir a la evolución observada de las carteras. Esta lectura es meramente cualitativa y no debe interpretarse como una atribución causal, pues el periodo de test es corto y comprende un único ciclo de corrección y recuperación. En conjunto, las curvas confirman en el tiempo lo observado en las métricas: las carteras del modelo crecen por encima del índice en los horizontes favorables, si bien con oscilaciones más pronunciadas.


Figura 6.13. Curvas de equity para la configuración top-10, para el dataset market.



Si comparamos las curvas por periodo de cada una de estas gráficas podemos apreciar que

existe un mejor rendimiento en las carteras para el dataset enriched en horizontes intermedios y más largos.

Figura 6.14. *Curvas de equity para la configuración top-10 para el dataset enriched.*



6.4.3. Discusión de los resultados

Reunidos los análisis de ambos conjuntos, cabe cerrar la evaluación retomando las dos preguntas de validación que la guiaron: si la herramienta genera valor frente al mercado de forma consistente y de dónde procede ese valor.

Respecto a la primera, la evaluación out-of-sample muestra que la herramienta sí genera valor frente al mercado en los horizontes cortos e intermedios (de 1 día a 2 meses), que son los que cuentan con un número de rebalanceos suficiente para una conclusión sólida. En esa franja las carteras superan al S&P 500 en rendimiento ajustado al riesgo y lo hacen de forma robusta, no en casos aislados: alcanzan ratios de Sharpe de hasta 1,18 a horizonte diario (conjunto enriched), 1,87 a horizonte semanal (conjunto market) y 1,55 a dos semanas (conjunto enriched), frente a un índice que se mueve entre 0,42 y 0,76. El comparador conservador (la cartera que combina el índice con un activo seguro) queda sistemáticamente por debajo del propio índice, al sacrificar retorno por estabilidad en un mercado de tendencia alcista neta; por tanto, si las

carteras baten al S&P 500 en *buy & hold*, con más razón superan a esa alternativa defensiva. Esta ventaja se consigue, no obstante, asumiendo una volatilidad y un máximo *drawdown* superiores a los del mercado, aunque contenidos: las caídas desde máximos se mantienen en niveles interpretables incluso atravesando el mercado bajista de 2022, muy lejos de los descensos catastróficos que producía el backtest antes de las correcciones de calidad de datos. La consistencia tiene, sin embargo, un límite claro: a partir de 3 meses el escaso número de rebalances y el efecto de borde impiden afirmar nada con solidez estadística, de modo que el rango de operación fiable de la herramienta queda acotado a los horizontes cortos e intermedios.

Respecto a la segunda pregunta, el valor no procede de un único componente ni se distribuye de forma uniforme. El factor más determinante es, con diferencia, el conjunto de datos: promediando sobre el resto de dimensiones, el ratio de Sharpe medio pasa de 0,43 en el conjunto market a 0,93 en el enriched. La información fundamental es, por tanto, la que dota de consistencia a las recomendaciones, especialmente a los horizontes intermedios, donde el conjunto enriched bate al índice de forma sistemática mientras que el market apenas lo consigue; a horizonte diario y semanal, en cambio, es la información de mercado la que rinde mejor. Este comportamiento sugiere que la señal de mercado y la fundamental capturan patrones de distinta persistencia temporal. Por detrás del conjunto de datos, la estrategia de optimización influye de forma moderada y el tamaño de cartera aún menos, mientras que la elección de variante (*long-only* o *long-short*) es prácticamente irrelevante en promedio. Dentro de las estrategias, el comportamiento es el esperable: la mínima varianza reduce la volatilidad frente a la máxima rentabilidad y, cuando la restricción de riesgo no es activa, las distintas formulaciones convergen a soluciones muy similares. En conjunto, la elección del conjunto de *features* pesa más en el resultado que la formulación concreta de optimización, un hallazgo relevante para el usuario de la herramienta: la palanca principal para obtener buenas recomendaciones es qué información se le proporciona al modelo, más que el ajuste fino de la estrategia.

Conviene, por último, situar estas cifras en su contexto financiero. Un ratio de Sharpe superior a la unidad se considera un rendimiento ajustado al riesgo notable en condiciones normales de mercado, umbral que las mejores configuraciones del modelo superan con holgura en los horizontes fiables. El ratio de Sortino, que penaliza solo la volatilidad de las caídas, se sitúa en esos casos claramente por encima del Sharpe (por ejemplo, 3,57 frente a 1,87 en la mejor configuración semanal del conjunto market), lo que revela una asimetría favorable: las caídas

son proporcionalmente menores que las subidas. La volatilidad de las carteras, del orden del 30%–50% frente al 14%–19% del índice, y el máximo *drawdown*, del orden del 20%–45% frente al 14%–18% del mercado, confirman que el mayor rendimiento se obtiene asumiendo un riesgo real superior al de la gestión pasiva. Finalmente, debe recordarse que las métricas de retorno total se refieren al periodo acumulado de *test* (aproximadamente tres años, de finales de 2021 a finales de 2024) y que las de los horizontes iguales o superiores a dos meses han de interpretarse con cautela por el reducido número de rebalanceos, agravado por el efecto de borde.


6.5. Explicabilidad de las decisiones

Además de evaluar el rendimiento, interesa poder explicar por qué el sistema propone una determinada cartera. Como se anticipó en el capítulo de diseño, la explicación se distribuye según la naturaleza de cada etapa: la selección de activos y la optimización de Markowitz son transparentes por construcción y se explican por trazabilidad directa, mientras que la red recurrente, único componente opaco, requiere una técnica post-hoc. Esta sección ilustra los tres análisis sobre dos casos representativos: el conjunto market a horizonte semanal (el de mejor rendimiento del estudio) y el conjunto enriched a horizonte diario (el de mejor rendimiento a esa frecuencia), en ambos casos para la configuración top-10 long-only.

6.5.1. Trazabilidad de la cadena de decisión

La primera forma de explicabilidad reconstruye, para una fecha de rebalanceo concreta, el recorrido de cada activo a lo largo de las etapas interpretables: el retorno que predice el modelo determina su posición en la ordenación, esa posición decide su inclusión en el conjunto de los K mejores, y sobre ese conjunto la optimización fija el peso final. La Figura 6.15 muestra esta cadena para el caso market a horizonte semanal: a la izquierda, el retorno predicho que ordena los activos; a la derecha, el peso que finalmente les asigna la optimización. Se observa que el peso no reproduce el orden del retorno predicho, pues la optimización pondera también el riesgo y las covarianzas entre activos, de modo que un activo con alta predicción puede recibir menos peso si aporta demasiado riesgo o correlación a la cartera.

Figura 6.15. Trazabilidad para un rebalanceo (conjunto market, horizonte semanal, top-10 long-only).



Izquierda: retorno predicho por el modelo, que ordena la selección. Derecha: peso asignado por la optimización de Markowitz. Fuente: Elaboración propia.


6.5.2. Descomposición de la optimización de Markowitz

La segunda forma de explicabilidad descompone el peso de cada activo en sus dos motores: su contribución al retorno esperado de la cartera ($w_i \mu_i$) y su contribución al riesgo, medido como la aportación a la varianza total ($w_i (\Sigma \mathbf{w})_i$). La Figura 6.16 presenta esta descomposición para el mismo rebalanceo del caso market: permite ver qué activos aportan rentabilidad esperada y cuáles concentran el riesgo de la cartera, haciendo explícito el compromiso que resuelve la optimización. Un activo puede recibir un peso moderado pese a una predicción alta si su contribución a la varianza es desproporcionada respecto a la del resto.

6.5.3. Atribución de variables de la red recurrente

La tercera forma de explicabilidad aborda el único componente opaco, la red recurrente, mediante Integrated Gradients (IG). Esta técnica reparte la predicción entre las variables de entrada integrando el gradiente a lo largo de un camino desde una línea base (el vector cero en el espacio escalado, que por el escalado robusto corresponde a la mediana de cada variable) hasta la entrada real, y respeta la estructura temporal al producir una atribución por cada par (variable, sesión) de la ventana. Agregando el valor absoluto de las atribuciones sobre una

Figura 6.16. Descomposición de la asignación de Markowitz por activo (conjunto market, horizonte semanal, top-10 long-only).



Izquierda: contribución al retorno esperado de la cartera. Derecha: contribución a la varianza total. Fuente: Elaboración propia.

muestra de ventanas de test se obtiene una importancia global de variables.

Las Figuras 6.17 y 6.18 muestran esa importancia para los dos casos. En el conjunto market a horizonte semanal, la predicción está dominada de forma acusada por el retorno diario de mercado (market_return_1d), el último retorno conocido, seguido muy de lejos por las variables binarias de sector: la señal se apoya casi por completo en la dinámica reciente del propio retorno. En el conjunto enriched a horizonte diario, aunque el retorno diario (market_return_1d) sigue siendo la variable más influyente, la importancia se reparte a continuación entre variables fundamentales, en particular las magnitudes financieras en escala logarítmica (capitalización de mercado, beneficio neto, ratio de EBITDA y free cash flow) y sus ratios, lo que refleja que cuando el modelo dispone de información fundamental, la incorpora de forma apreciable junto a la dinámica de mercado.

La atribución se calcula sobre una única semilla del ensemble por simplicidad, por lo que ofrece una lectura orientativa de las variables relevantes más que una medida definitiva. Los tres análisis, tomados en conjunto, permiten reconstruir la decisión completa (de la variable de entrada a la predicción, de la predicción al ranking y del ranking al peso final), materializando la noción de explicabilidad como trazabilidad discutida en el estado del arte.

Figura 6.17. *Importancia global de variables mediante Integrated Gradients (conjunto market, horizonte semanal).*





Figura 6.18. *Importancia global de variables mediante Integrated Gradients (conjunto enriched, horizonte diario).*



Más allá de los dos casos ilustrados, el análisis de la importancia global de variables sobre el conjunto de los modelos, distinguiendo por dataset y horizonte, permite extraer una lectura común. En el conjunto market el retorno diario de mercado (`market_return_1d`) es la variable más influyente en todos los horizontes, con una cuota de la atribución total que oscila entre el 42 % del horizonte diario y el 91 % del bisemanal, y que supera varias veces a la siguiente variable; el resto de la señal recae en las variables binarias de sector, de importancia marginal. En el conjunto enriched el retorno diario sigue encabezando la atribución en la mayoría de horizontes (diario, semanal, quincenal, mensual y semestral), aunque con una cuota más moderada (entre el 15 % y el 52 %) al competir con las variables fundamentales; solo en los horizontes de dos y tres meses la importancia se reparte de forma más homogénea y pasan a encabezarla magnitudes fundamentales en escala logarítmica. En conjunto, se aprecia una predominancia general de la variable de retorno, lo que apunta a que buena parte de la capacidad predictiva del modelo procede de la historia reciente de precios que conoce, mientras que la información fundamental actúa como señal complementaria que gana peso relativo cuando está disponible y a horizontes intermedios.

6.6. Limitaciones identificadas

Es importante tener en cuenta que los resultados deben interpretarse como evidencia experimental sobre la utilidad potencial de la herramienta, no como una garantía de rentabilidad. Se identifican las siguientes limitaciones como condicionantes para su uso:

- La señal predictiva sobre acciones individuales es débil, especialmente a corto plazo. Por tanto, la herramienta resulta más adecuada como apoyo a la selección y al control del riesgo que como mecanismo autónomo de decisión, y sus recomendaciones deben contrastarse con el perfil y el criterio del inversor.
- El periodo de test comprende aproximadamente tres años, desde finales de 2021 hasta finales de 2024. Aunque incluye la corrección de 2022 y la recuperación posterior, no cubre suficientes ciclos de mercado para asegurar que el comportamiento observado se mantenga en otros regímenes. Esta limitación es especialmente relevante a partir del horizonte de dos meses, donde solo se dispone de 16 a 4 rebalanceos; por ello, los resultados de tres y seis meses deben ser tomado con carácter orientativo.

- Las rentabilidades no incorporan costes de transacción, deslizamiento, impuestos ni restricciones reales de liquidez. El rendimiento neto sería previsiblemente inferior, sobre todo en las estrategias con rebalanceos frecuentes o posiciones cortas, por lo que estos costes deben ser tenidos en cuenta fuera de las recomendaciones obtenidas por la herramienta.
- El límite fijo del 20 % de volatilidad anual no siempre es alcanzable, especialmente a horizontes largos. Cuando ninguna cartera factible satisface la restricción, el sistema aplica una asignación equiponderada de reserva. Esto preserva la continuidad del proceso, pero deja de representar la estrategia de Markowitz solicitada. En una aplicación operativa convendría adaptar el umbral al horizonte y al perfil de riesgo, o ampliar el universo con activos menos volátiles.
- La estimación del riesgo se basa en la covarianza muestral, sensible al periodo utilizado y a cambios en las relaciones entre activos.

6.7. Conclusiones de la evaluación

La evaluación confirma que la herramienta puede generar recomendaciones competitivas frente al S&P 500, pero no de forma uniforme para cualquier configuración. Los resultados más favorables se concentran en determinados horizontes y conjuntos de información: market destaca a una semana, mientras que enriched muestra un comportamiento más consistente en varios horizontes al incorporar información fundamental. Esta diferencia indica que la elección de los datos y del plazo de inversión condiciona más el resultado que adoptar una arquitectura recurrente o una formulación de Markowitz concreta.

La aportación del sistema no procede de predecir con precisión cada retorno. El ensemble estabiliza las estimaciones, pero la capacidad de ordenar acciones sigue siendo limitada, sobre todo a corto plazo; además, la atribución mediante IG muestra que la señal descansa principalmente en la historia reciente de precios, complementada por los fundamentales en enriched. El valor práctico surge de combinar esa señal débil con la selección top- K y la gestión del riesgo, aunque la mejora frente a una asignación equiponderada de los mismos activos no es sistemática.

En consecuencia, la herramienta cumple su propósito como soporte para explorar alternativas

de cartera, comparar perfiles de rentabilidad y riesgo y hacer trazable cada recomendación. No permite afirmar que exista una estrategia ganadora universal: las configuraciones favorables conviven con otras que asumen mayor volatilidad o drawdown sin compensación suficiente. Su uso adecuado exige seleccionar el horizonte y el conjunto de datos conforme al perfil del inversor, considerar con cautela los resultados sustentados en pocos rebalances e incorporar costes y condiciones reales de mercado antes de cualquier aplicación práctica.

7. Conclusiones y trabajo futuro

7.1. Conclusiones

Completadas la construcción y la evaluación de la herramienta, cabe recoger las conclusiones del Trabajo Fin de Máster, relacionando los resultados obtenidos con los objetivos planteados en el Capítulo 3 y valorando en qué medida se han alcanzado.

El objetivo general consistía en diseñar, construir y validar una herramienta software de apoyo a la construcción de carteras de inversión, que combina la estimación del comportamiento futuro de los activos con la optimización de la relación entre rentabilidad y riesgo, y que ofrece al usuario distintas alternativas de recomendación. Las conclusiones se organizan según los objetivos específicos.

- **Estado del arte.** La revisión de la literatura sobre predicción de series financieras y construcción de carteras fundamentó las decisiones de diseño adoptadas, en particular la elección de las redes recurrentes para la estimación y del marco de Markowitz para la asignación de pesos.
- **Construcción del dataset.** Se consolidó un conjunto de datos de dieciséis años (2009–2024) de precios diarios y estados financieros anuales de empresas de gran capitalización, clasificadas en once sectores, con los precios normalizados a euros y organizados en ventanas deslizantes de veinte sesiones. El muestreo estratificado se cerró en dos iteraciones y alcanzó una cobertura suficiente para el trabajo, aunque por debajo de la significación estadística inicialmente prevista debido a la calidad irregular de las fuentes.
- **Modelos predictivos.** La selección del modelo se realizó mediante optimización bayesiana de hiperparámetros, con un estudio independiente por conjunto de datos y horizonte que minimiza el error de validación y explora arquitectura, entrenamiento y regularización. Ningún tipo de red resultó uniformemente superior (se reparten RNN, GRU y LSTM según el horizonte) y ninguna configuración ganadora fue bidireccional. Sobre el conjunto de test, el ensemble de cinco semillas mostró una capacidad de ordenación débil: prácticamente nula a horizonte corto y solo algo apreciable a plazos intermedios. Se

confirma así que anticipar el retorno de acciones líquidas es un problema de muy baja relación señal-ruido, especialmente a horizonte diario.

- **Construcción de carteras.** Se implementó un módulo de optimización de Markowitz con cuatro estrategias, dos variantes (long-only y long-short) y restricción de volatilidad, resuelto mediante programación cuadrática convexa. El módulo opera de forma estable en el backtesting, generando los pesos en cada rebalanceo y recurriendo a una asignación equiponderada de reserva cuando el problema resulta infactible.
- **Recomendación de carteras y contraste con el mercado.** La herramienta ofrece varias alternativas de recomendación (distintos conjuntos de datos, estrategias y variantes) para que el usuario elija. Su validación out-of-sample sobre el conjunto de test, con el S&P 500 como referencia, revela una dependencia clara del horizonte y del conjunto de datos. A horizonte diario la mejora frente a una asignación equiponderada es marginal, coherente con la débil señal predictiva. El conjunto market destaca a horizonte semanal, donde llega a superar con holgura el rendimiento ajustado al riesgo del índice, mientras que el conjunto enriched ofrece un comportamiento más consistente en varios horizontes al incorporar información fundamental. Esa ventaja, no obstante, suele acompañarse de una volatilidad y unas caídas mayores que las del mercado, y a los plazos más largos se apoya en muy pocos rebalanceos, lo que limita su significación.

En síntesis, se ha desarrollado un sistema completo y reproducible que cubre el ciclo íntegro desde la ingesta de datos hasta la evaluación de carteras frente al mercado, y que satisface los requisitos definidos. Su aportación principal no reside en predecir con precisión cada retorno, sino en combinar una señal débil con la selección de activos y la gestión del riesgo para producir recomendaciones competitivas en determinados horizontes y conjuntos de información. La herramienta cumple así su propósito de asistir en la construcción de carteras, ofreciendo alternativas de recomendación que el usuario puede examinar de forma trazable, si bien su utilidad depende de elegir el horizonte y los datos conforme al perfil del inversor y de incorporar costes y condiciones reales antes de cualquier aplicación práctica.

7.2. Cumplimiento de los requisitos

Más allá de los objetivos, conviene verificar en qué medida el sistema desarrollado satisface los requisitos funcionales y no funcionales definidos en el Capítulo 4. La Tabla 7.1 resume el estado de cumplimiento de los requisitos funcionales.

Cuadro 7.1. *Evaluación del cumplimiento de requisitos funcionales.*

Requisito	Descripción	Estado
RF-01	Descarga de datos históricos de precios	Cumplido
RF-02	Selección del universo de activos	Cumplido
RF-03	Limpieza y preprocesamiento	Cumplido
RF-04	Partición temporal sin data leakage	Cumplido
RF-05	Entrenamiento de modelos recurrentes	Cumplido
RF-06	Generación de predicciones	Cumplido
RF-07	Comparación con el índice de mercado (S&P 500) como referencia	Cumplido
RF-08	Optimización de Markowitz	Cumplido
RF-09	Múltiples configuraciones de cartera	Cumplido
RF-10	Rebalanceo periódico	Cumplido
RF-11	Backtesting sobre datos históricos	Cumplido
RF-12	Métricas de rendimiento financiero	Cumplido

Los requisitos de la fase de predicción (RF-01 a RF-06) y de la construcción de carteras y backtesting (RF-07 a RF-12) están completamente implementados. El S&P 500, como referencia de mercado (RF-07), se evalúa sobre el mismo periodo de test y con idéntica malla de rebalanceo que las carteras del modelo. Entre los requisitos no funcionales (Tabla 7.2) destacan la reproducibilidad (RNF-01), sustentada en semillas fijas, lockfile de dependencias y una partición temporal determinista, y la modularidad (RNF-02), que permite ejecutar cada fase de forma independiente.

Cuadro 7.2. *Evaluación del cumplimiento de requisitos no funcionales.*

Requisito	Descripción	Valoración
RNF-01	Reproducibilidad	Alta
RNF-02	Modularidad	Alta
RNF-04	Gestión de dependencias	Alta
RNF-07	Ausencia de data leakage	Alta

7.3. Líneas de trabajo futuro

El trabajo abre varias líneas de mejora que responden a las limitaciones identificadas y amplían el alcance de los resultados.

- **Evaluación sobre periodos más amplios y de distinto signo.** La significación de los horizontes de medio plazo está limitada por el escaso número de rebalanceos disponibles. Ampliar la ventana histórica y cubrir fases bajistas y laterales, además del tramo evaluado, permitiría estimar el rendimiento con mayor robustez e incorporar costes de transacción y una tasa libre de riesgo realista para juzgar si la ventaja sobre el mercado es sostenible.
- **Arquitecturas y datos adicionales.** Cabe evaluar arquitecturas basadas en atención o en grafos, que capturan relaciones entre empresas, así como incorporar datos textuales o macroeconómicos que anticipen movimientos de mercado y complementen la información de precios y fundamentales.
- **Ampliación del universo y de las features.** La extensión al segmento small-cap, ya contemplado en el diseño, y a otros mercados evaluaría el comportamiento en entornos menos eficientes. En paralelo, incorporar como features magnitudes ya disponibles en el dataset, como la capitalización o el PER, enriquecería la representación de cada activo.
- **Personalización y mejora de la optimización.** Integrar técnicas de recomendación o aprendizaje por refuerzo adaptaría las carteras al perfil de cada inversor. Del lado de la optimización, sustituir la covarianza muestral por métodos de regularización o modelos factoriales mejoraría la estabilidad de las asignaciones, especialmente con universos mayores.

8. Anexo A. Código fuente y datos analizados

El código fuente se encuentra en el siguiente repositorio: https://github.com/Edelmin/portfolio_recsys/

No es posible adjuntar los datos de estados financieros procedentes de TIKR. Dichos datos fueron facilitados por un tercero que abonó una suscripción de pago para obtenerlos y que no autoriza su publicación ni su redistribución. Por este motivo, y con el fin de respetar las condiciones de licencia y los derechos de la fuente original, estos datos quedan excluidos del material que acompaña a la memoria.

9. Anexo B. Curvas de aprendizaje y parada temprana

Este anexo recoge las curvas de aprendizaje del reentrenamiento multi-semilla de la configuración ganadora de cada horizonte, para los conjuntos *market* y *enriched*, complementando la figura ilustrativa del horizonte semanal incluida en el capítulo de evaluación (Sección 6.2.1). En cada figura, el panel superior muestra la pérdida de **validación** por época (una curva por semilla, con la época del mejor *checkpoint* marcada) y el inferior la de **entrenamiento**. El comportamiento es análogo en todos los horizontes: la validación se estabiliza en pocas épocas y la parada temprana conserva el mejor *checkpoint*.

9.1. Conjunto *market*

Figura 9.1. Curvas de aprendizaje por semilla (conjunto *market*, horizonte 1 día).




Figura 9.2. *Curvas de aprendizaje por semilla (conjunto market, horizonte 2 semanas).*




Figura 9.3. *Curvas de aprendizaje por semilla (conjunto market, horizonte 1 mes).*




Figura 9.4. *Curvas de aprendizaje por semilla (conjunto market, horizonte 2 meses).*




Figura 9.5. *Curvas de aprendizaje por semilla (conjunto market, horizonte 3 meses).*





Figura 9.6. *Curvas de aprendizaje por semilla (conjunto market, horizonte 6 meses).*



9.2. Conjunto *enriched*

Figura 9.7. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 día).*




Figura 9.8. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 2 semanas).*




Figura 9.9. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 1 mes).*




Figura 9.10. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 2 meses).*




Figura 9.11. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 3 meses).*





Figura 9.12. *Curvas de aprendizaje por semilla (conjunto enriched, horizonte 6 meses).*



Bibliografía

- Aksehir, Z. D., & Kılıç, E. (2024). Analyzing the critical steps in deeplearning-based stock forecasting: a literature review. <https://doi.org/10.7717/peerj-cs.2312>
- Baguda, Y. S., AlJahdali, H. M., & Taha, A. A. (2025). Dynamic Portfolio Return Classification Using Price-Aware Logistic Regression. *Mathematics*, 13(11). <https://doi.org/10.3390/math13111885>
- Basel Committee on Banking Supervision. (2026). Basel Framework. *The Basel Framework*.
- Boloş, M.-I., Rusu, Ş., Leordeanu, M., Sabău-Popa, C. D., Perţicaş, D. C., & Crişan, M.-I. (2025). K-Means Clustering for Portfolio Optimization: Symmetry in Risk–Return Tradeoff, Liquidity, Profitability, and Solvency. *Symmetry*, 17(6). <https://doi.org/10.3390/sym17060847>
- Castro Sesme, G. F. (2017). Aspectos generales del mercado financiero. *ECUADORIAN SCIENCE JOURNAL*.
- Černevičienė, J., & Kabašinskas, A. (2024). Explainable artificial intelligence (XAI) in finance: a systematic literature review. <https://doi.org/10.1007/s10462-024-10854-8>
- Chaweewanchon, A., & Chaysiri, R. (2022). Markowitz Mean-Variance Portfolio Optimization with Predictive Stock Selection Using Machine Learning. <https://doi.org/10.3390/ijfs10030064>
- Comisión Nacional del Mercado de Valores. (s.f.-a). *Glosario* [Accedido el 30 de junio de 2025]. <https://www.cnmv.es/portal/Inversor/Glosario?id=0&letra=A&idIng=1>
- Comisión Nacional del Mercado de Valores. (s.f.-b). *Glosario* [Accedido el 30 de junio de 2025]. <https://www.cnmv.es/portal/Inversor/Glosario?id=0&letra=C&idIng=1>
- Cortés, D. G., Onieva, E., Pastor, I., Trinchera, L., & Wu, J. (2024). Portfolio construction using explainable reinforcement learning. *Expert Systems*, 41(11). <https://doi.org/10.1111/exsy.13667>
- Cui, Q., Zhao, T., & Cui, T. (2025). Mitigating Left-tail Risk in Volatility Scaling: Introducing a Volatility Floor Correction. *Sage Open*, 15(4). <https://doi.org/10.1177/21582440251388777>
- Fonseca, A. R., Leles, M. C. R., Moreira, M. G., Vale-Cardoso, A. S., Pereira, M. V. L., Sbruzzi, E. F., & Nascimento, C. L. (2021). Testing the Application of Support Vector Machine(SVM) to Technical Trading Rules. <https://doi.org/10.1109/SysCon48628.2021.9447068>

- Freeborough, W., & van Zyl, T. (2022). Investigating Explainability Methods in Recurrent Neural Network Architectures for Financial Time Series Data. <https://doi.org/10.3390/app12031427>
- García Mazo, C. M. (2025). Aplicación del Modelo Media Varianzacon Machine Learning para Optimizaciónde Portafolios de Inversión. *European Public & Social Innovation Review*. <https://doi.org/10.31637/epsir-2025-1844>
- Guan, M., & Liu, X.-Y. (2021). Explainable Deep Reinforcement Learning for Portfolio Management: An Empirical Approach. <https://doi.org/10.1145/3490354.3494415>
- Hanyang, C., Tian, W., Jessada, K., & Sirikham, A. (2024). Learning A-Share Stock Recommendation from Stock Graph andHistorical Price Simultaneously. <https://doi.org/10.3390/electronics13224427>
- Kirby, C. (2025). Using Daily Stock Returns to Estimate the Unconditional and Conditional Variances of Lower-Frequency Stock Returns. <https://doi.org/10.3390/risks13100190>
- Ko, C.-R., & Chang, H.-T. (2021). *LSTM-based sentiment analysis for stock price forecast Ching-Ru Ko1 and Hsien-Tsung Chang* (inf. téc. N.º target). <https://doi.org/10.7717/peerj-cs.408>
- Kumari, S. (2024). AI-Enhanced Portfolio Management: Leveraging Machine Learning for Optimized Investment Strategies in 2024. *Journal of Informatics Education and Research*, 4. <https://doi.org/10.52783/jier.v4i3.1487>
- László Vancsura, T. T., & Bareith, T. (2025). Navigating AI-Driven Financial Forecasting: A Systematic Review of Current Status and Critical Research Gaps. <https://doi.org/10.3390/forecast7030036>
- Lee, Y., Kim, Y., Sanz-Cruzado, J., Mccreadie, R., & Lee, Y. (2024). Stock Recommendations for Individual Investors: A Temporal Graph Network Approach with Mean-Variance Efficient Sampling. *Proceedings of the 5th ACM International Conference on AI in Finance*, 795-803. <https://doi.org/10.1145/3677052.3698662>
- Leung, M.-F., Jawaid, A., Ip, S.-W., Kwok, C.-H., & Yan, S. (2023). A portfolio recommendation system based on machine learning and big data analytics. *Data Science in Finance and Economics*, 3(2), 152-165. <https://doi.org/10.3934/dsfe.2023009>
- Mancinelli, D., & Oliva, I. (2023). Constant or Variable? A Performance Analysis among Portfolio Insurance Strategies. <https://doi.org/10.3390/risks11060105>

- Markowitz, H. (1952). Portfolio Selection [Disponible en https://www.math.hkust.edu.hk/~maykwok/courses/ma362/07F/markowitz_JF.pdf]. *The Journal of Finance*.
- Martínez-Barbero, X., Cervelló-Royo, R., & Ribal, J. (2024). Portfolio Optimization with Prediction-Based Return Using Long Short-Term Memory Neural Networks: Testing on Upward and Downward European Markets. <https://doi.org/10.1007/s10614-024-10604-6>
- Mcwera, A., & Clement Mba, J. (2023). Predicting stock market direction in South African banking sector using ensemble machine learning techniques. *Data Science in Finance and Economics*. <https://doi.org/10.3934/DSFE.2023023>
- Mendizábal Zubeldia, A., Miera Zabalza, L. M., & Zubia Zubiaurre, M. (2002). El modelo de Markowitz en la gestión de carteras. *Economics*. <https://doi.org/10.5295/cdg.19217am>
- Michis, A. A. (2022). Multiscale Partial Correlation Clustering of StockMarket Returns. *Journal of Risk and Financial Management*. <https://doi.org/10.3390/jrfm15010024>
- Mintarya, L. N., Halim, J. N., Angie, C., Achmad, S., & Kurniawan, A. (2023). Machine learning approaches in stock market prediction: A systematic literature review [7th International Conference on Computer Science and Computational Intelligence 2022]. *7th International Conference on Computer Science and Computational Intelligence 2022*, 216, 96-102. <https://doi.org/10.1016/j.procs.2022.12.115>
- Mohamad, A. H. H., Ab-Rahim, R., & Kadri, N. (2025). Future Trend of Artificial Intelligence and StockMarket: A Comprehensive Bibliometric Analysis. *International Journal of Economics and Financial Issues*. <https://doi.org/10.32479/ijefi.19272>
- Mugel, S., MarioAbad, Bermejo, M., Sánchez, J., Lizaso, E., & Orús, R. (2021). Hybrid quantum investment optimization with minimal holding period. <https://doi.org/10.1038/s41598-021-98297-x>
- Munki, C., Yongjae, L., & Woo Chang, K. (2023). Mean-Variance Efficient Collaborative Filtering for Stock Recommendation. <https://doi.org/10.48550/arXiv.2306.06590>
- Naidoo, T., Moores-Pitt, P., Muzindutsi, P.-F., & Isah, K. O. (2025). Analysing investor sentiment and stock market volatility of the JSE size-based indices: a GARCH-MIDAS approach. <https://doi.org/10.1057/s41283-025-00165-9>
- Pagliaro, A. (2023). Forecasting Significant Stock Market Price Changes Using Machine Learning: Extra Trees Classifier Leads. <https://doi.org/10.3390/electronics12214551>

- Patrick, K. A., Sudarso, K. W., & Taufik, F. (2024). Economic Theory and Machine Learning Integration in Asset Pricing and Portfolio Optimization: A Bibliometric Analysis and Conceptual Framework. *Journal of Computer Science*.
- Petrozziello, A., Troiano, L., Serra, A., Jordanov, I., Storti, G., Tagliaferri, R., & Rocca, M. L. (2022). Deep learning for volatility forecasting in asset management. <https://doi.org/10.1007/s00500-022-07161-1>
- Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead.
- Saberironaghi, M., Ren, J., & Saberironaghi, A. (2025). Stock Market Prediction Using Machine Learning and Deep Learning Techniques: A Review. <https://doi.org/10.3390/appliedmath5030076>
- Sanz-Cruzado Puig, J., Droukas, N., & McCreddie, R. (2024). FAR-Trans: An Investment Dataset for Financial Asset Recommendation. <https://doi.org/10.5525/gla.researchdata.1658>
- Serrano Checca, R., Flores Flores, F. R., & Pérez Marroquín, R. D. (2024). Eficiencia y Retorno de las Estrategias de Inversión Basadas en IA en Carteras Diversificadas. *Business innovation sciences*. <https://doi.org/10.5281/zenodo.13845143>
- Seyed Mostafa, M., & Ali Reza, H. (2025). Key technical indicators for stock market prediction. *Machine Learning with Applications*, 20, 100631. <https://doi.org/10.1016/j.mlwa.2025.100631>
- Sutiene, K., Schwendner, P., Sipos, C., Lorenzo, L., Mirchev, M., Lameski, P., Kabasinskas, A., Tidjani, C., Ozturkkal, B., & Cerneviene, J. (2024). Enhancing portfolio management using artificial intelligence: literature review.
- Switzer, L. N. (2010). The behaviour of small cap vs. large cap stocks in recessions and recoveries: Empirical evidence for the United States and Canada. *The North American Journal of Economics and Finance*, 21(3), 332-346. <https://doi.org/10.1016/j.najef.2010.10.002>
- Tsai, P.-F., Gao, C.-H., & Yuan, S.-M. (2023). Stock Selection Using Machine Learning Based on Financial Ratios. *Mathematics*, 11(volumes). <https://doi.org/10.3390/math11234758>
- Valentine, A. M., Tani, M., & Sharpe, K. (2026). Do board-CEO ties in outsider CEO succession raise companies' returns? *International Journal of Managerial Finance*, 22(4), 974-997. <https://doi.org/10.1108/ijmf-12-2024-0688>

- Vásquez Sáenz, J., Quiroga, F. M., & Bariviera, A. F. (2023). Data vs. information: Using clustering techniques to enhance stock returns forecasting. *International Review of Financial Analysis*, 88(concern), 102657. <https://doi.org/10.1016/j.irfa.2023.102657>
- Weber, P., Carl, K. V., & Hinz, O. (2024). Applications of Explainable Artificial Intelligence in Finance—a systematic review of Finance, Information Systems, and Computer Science literature. <https://doi.org/.org/10.1007/s11301-023-00320-0>
- Wu, D., & Li, X. (2025). A Systematic Literature Review of Financial Product Recommendation Systems. <https://doi.org/10.3390/info16030196>
- Zheng, H., Zhou, Z., & Chen, J. (2021). RLSTM: A New Framework of Stock Prediction by Using Random Noise for Overfitting Prevention (J. C. Claussen, Ed.). *Computational Intelligence and Neuroscience*, 2021(1). <https://doi.org/10.1155/2021/8865816>